



教育背景

上海交通大学 | 设计 | 硕士 | 上海交大-南加州大学文化创意学院

2024.09-2027.06 上海

• 奖学金: 2025 学年国家奖学金 排名: 2/14 GPA: 3.83/4.00 主修课程: 管理学概论、公司财务、媒介经营与管理、数字媒体技术、策展实践

University of New South Wales | Exchange Program | Business School (QS 19)

2026.02-2026.06 悉尼

• 奖学金: Cheung Kong Scholarship 主修课程: Artificial Intelligence Fluency、Social Entrepreneurship Practicum、Personal Financial Planning

北京大学 | 暑期交换 | 北京大学智能学院与文化产业研究院

2025.07-2025.08 北京

• 主修课程: 智能算法赋能因子挖掘、深度学习在金融市场时序预测中的应用、量化投资策略的构建与优化、具身智能、文化创意产业调研

东北电力大学 | 广播电视编导 | 学士 | 艺术学院

2020.09-2024.06 吉林

• 奖学金: 2022、2023 学年国家奖学金 排名: 1/299 GPA: 4.34/5.00 主修课程: 数字图像设计、影视创作实践、非线性编辑、视听语言

工作经历 - AI 技术能力

腾讯集团 PCG 平台与内容事业群 | 智能创作平台部 AI 产品中心

AI 产品策划

2026.06 至今 深圳

核心业务: Work Rally | B 端腾讯视频 AI 影视智能制作平台 | <https://workrally.qq.com/film>

- 增长策略: 针对新功能用户认知不足、使用门槛高及 UV 渗透率低的问题, 梳理功能发布至用户使用的完整转化漏斗, 牵头设计「轮播弹窗+新手任务」Feature Onboarding 机制, 推动新功能从上线、触达、理解到使用的增长闭环。
- 用户体验: 深入分析影视创作团队在资产流转、任务协作与内容审核中的痛点, 独立完成站内资产库与标签能力产品 Demo, 协同研发落地前端交互与管理后台、分级权限与精准触达机制, 3 周完成 285 项用例验收、118 个问题排查修复, 推动需求上线, 完成功能影像宣发, 资产库用户活跃度增长 32.7%。
- 创新执行: 洞察无线画布模式下多镜头内容无法快速预览的需求, 独立设计轻量化「快速剪辑」节点, 支持粗剪编排、倍速预览、下载导出及协同审核; 3 天完成可交互 Demo 并交付超级创作团队测试, 快速验证方案可行性。

北京字节跳动科技有限公司 | 剪辑 AI 产品

AI 算法策略

2025.10-2026.02 深圳

核心业务: 剪小映 | C 端 AI 影像智能成片产品

- 消费者洞察与品牌定位: 基于种子用户内测数据, 拆解不同年龄层消费者在影像记录、情感表达及内容分享方面的需求差异, 识别用户对情绪陪伴和个性化表达的核心诉求, 推动产品价值主张由「被动成片工具」升级为「主动影像陪伴者」。
- 产品创新与数据分析: 围绕文案、音乐、视觉包装及内容推荐 4 个消费者体验维度, 搭建包含 16 项细分指标的 AI Agent 量化评测体系; 推动 12 项核心效果策略的模型选型与提示工程优化, 支持 11 轮策略迭代, 用户满意度提升 12%。
- 跨职能领导与卓越执行: 协同算法、研发及产品搭建 Multi-Agent 智能语义剪辑架构, 负责复杂指令理解及推荐策略调优, 成片活跃采纳率提升 9.83%。

上海阶跃星辰智能科技有限公司 | AI 商业化

AI 产品经理

2025.05-2025.08 上海

核心业务: Step Audio 2 | 面向企业客户的端到端语音 AI 基础模型

- 市场与客户洞察: 深入研究金融、汽车及智能外呼等行业的消费者与客户使用场景, 识别语音交互在自然度、准确性及方言适配方面的关键需求, 形成针对不同市场场景的 MaaS 层 AI 语音解决方案。
- 商业分析与产品创新: 3 天搭建语音模型评测框架, 独立拉齐 105 个细分维度、525 条评测剧本及验收标准, 为产品迭代与商业决策提供量化依据。
- 整合上市与团队协作: 协同算法、数据、工程、开放平台及外部客户, 推动训练数据回流、模型调优和版本上线; 支持与中国移动、吉利汽车的产品合作与 WAIC 业务交付, 并主动策划产品传播视频, 助力 Step Audio 2 完成市场发布。

阿里巴巴国际数字商业集团 | AI Business

AI 产品运营

2024.03-2024.09 杭州

核心业务: Taobao Global 淘宝海外版 | 跨境电商 AI 增长解决方案

- 市场洞察: 针对跨境电商中的语言翻译偏差、消费文化差异及本地表达不准确等问题, 分析目标市场消费者与商家需求, 提出 3 项模型迭代需求, 落地 6 项多语言本地化策略并完成 8 轮效果测试, 支持淘宝海外新加坡站 AI 多语言版本上线。
- 电商营销: 围绕国际站中小商家的 SEO 流量与海外获客需求, 独立设计 AI 图文营销内容解决方案, 覆盖需求分析、内容生成、测试验收、渠道投放及效果追踪, 推动方案全量落地, 营销内容生产效率提升 35%。
- 项目管理: 建立「模型迭代-A/B 测试效果追踪-数据回流」闭环, 协同算法及业务优化模型效果; 支持团队实现自研模型日均调用量从 0 增长至 1 亿。

实践项目 - AI 内容生产

上海广播电视台 SMG 故宫百年专题《AIGC 穿越 600 年: 从紫禁城到故宫博物院》

AIGC 特约编辑

2025.09-2025.10

- 视频制作: 担任 AIGC 特约编辑, 从剧本策划到史料收集, 从 AI 生图到史实校审, 从 AI 视频到剪辑成片, 全流程主导 AI 视频全流程内容制作;
- 影像成果: 为上海广播电视台「故宫百年·四海同辉」特别报道制作《AIGC 穿越 600 年》, 被中央网信办评为“2025 中国正能量网络传播 AI 精品案例”。

腾讯集团 CDG 市场与公关部 MPR 鹅创营

腾讯传播研究生

2025.05-2025.06

- 用户研究: 通过定量问卷与 30+场跨文化定性访谈洞察家长及青少年需求, 为互联网平台的科技传播提供可落地策略方案;
- 品牌营销: 策划「短视频+图文+社媒」内容组合, 强化「腾讯擅长打造国民级工具」的品牌认知。

国家级大学生创新项目《AIGC 赋能全链路数字设计产学研协同创新的应用研究》

团队第一负责人

2023.09-2024.06

- 创意成果: 担任北京大学制作 AI 画册《白马二十四时》视觉设计; 带领团队为上海交大制作 AI 短片《十年后的你在哪儿》《交大建校 130 周年公告》。

竞赛荣誉

荣誉奖项: 本硕三年教育部国家奖学金(100%)、中国大学生自强之星(0.15%)、省优秀大学生(100%)、校长奖学金(0.1%)等荣誉称号 35 项

学术竞赛: “挑战杯”全国大学生课外学术科技作品竞赛一等奖等学术科技竞赛全国一等奖 7 项、国家级荣誉 25 项、省级荣誉 25 项

- | | | | |
|----------------------|-------|-----------------------|-------|
| “挑战杯”全国大学生课外学术科技作品竞赛 | 全国一等奖 | 米兰设计周·中国高校设计学科师生优秀作品展 | 全国一等奖 |
| 全国三维数字化创新设计大赛年度总决赛 | 全国一等奖 | 全国大学生节能减排社会实践与科技竞赛 | 全国一等奖 |
| 中国虚拟现实大赛 | 全国一等奖 | 全国大学生电力创新设计竞赛 | 全国一等奖 |

自我评价

- 专业能力: 开发- Code Buddy (Claude Opus 4.8 | DeepSeek V4 | GPT CodeX); 设计- Figma DevMode; 创作- Seedance | Kling 3.0 | TapNow | LibTV
- 英语水平: 全国大学生英语竞赛全国特等奖(100%), IELTS 6.5, CET-4 600, CET-6 516, 可作为工作语言, 具备海外交换经历, 英语听说读写能力过硬
- 工作实践: 上交人工智能协会科创部负责人、3 篇论文发表、4 段国家级大创项目、5 段实习工作经验、6 项实用新型专利、7 项科创竞赛全国一等奖
- Consumer is Boss, 专业、真诚、可靠、持续成长, 以 AI + 创意驱动品牌创新, 以主人翁精神, 致力于可落地的生意增长, 为品牌结果负责!

Education

Shanghai Jiao Tong University (SJTU)**Shanghai, China***Master of Design, USC-SJTU Institute of Cultural and Creative Industry (ICCI) Sep 2024 – Jun 2027 (Expected)*

- Honors: 2025 Academic Year National Scholarship (Top 1%), GPA: 3.83/4.0 (Rank: 2/14)
- Courses: Media Operations and Management, Research and Statistics in Cultural and Creative Industries
- Societies: Member of SJTU Artificial Intelligence Association (Tech Innovation Lead)

University of New South Wales (UNSW)**Sydney, Australia***Exchange Program, Business School**Feb 2026 – Jun 2026*

- Honors: Cheung Kong Scholarship | Courses: Social Entrepreneurship Practicum, Personal Financial Planning

Peking University**Beijing, China***Exchange Program, School of Artificial Intelligence & Institute for Cultural Industries**Jul 2025 – Aug 2025*

- Courses: Embodied Intelligence and Value Co-creation, Deep Learning for Financial Markets

Northeast Electric Power University**Jilin, China***Bachelor of Arts in Radio and Television Directing, College of Art**Sep 2020 – Jun 2024*

- Scholarship: 2022 & 2023 Academic Year National Scholarship (Top 1%), GPA: 4.34/5.0 (Rank: 1/299).
- Courses: Digital Image Design, Film & Television Creation Practice, Non-linear Editing, Audio-Visual Language

Experience

ByteDance Inc.**Shenzhen, China***AI Native Product Strategy Intern | CapCut/Jianying**Oct 2025 – Feb 2026*

- **Product Evolution:** Defined requirements for "Jian Xiaoying" (AI Native product), shifting the value proposition from passive editing to "Active Companionship" based on segmented user data.
- **Evaluation System:** Established a quantitative framework for AI Agents, defining 16 metrics (Text, Music, Edit, Recs) and leading 11 rounds of strategy optimization, resulting in a 12% increase in user satisfaction.
- **Algorithmic Strategy:** Supported the transition from template matching to semantic-driven intelligent editing, performed Prompt Engineering and model selection for 12 key effect strategies.
- **Technical Architecture:** Orchestrated a Multi-Agent semantic editing framework. Managed ChatBot personality definition and instruction-following tuning. Achieved a 9.83% lift in video adoption rates.

StepFun (Shanghai Jieyue Xingchen Intelligent Technology Co., Ltd.)**Shanghai, China***AI Product Manager Intern | AI Commercialization Department**July 2025 – Sep 2025*

- **MaaS Commercialization:** Managed B-end strategy for Step Audio 2 (TTS/ASR/AQAA end-to-end models).
- **Efficiency Hack:** Built a comprehensive audio evaluation scheme in 3 days; synchronized standards across 105 domains with 525 scripts, increasing evaluation frequency from 1x/month to 2x/week.
- **Industry Solutions:** Developed AI voice solutions for Finance, Automotive (Geely Auto), and Outbound Call sectors. Delivered the Shanghaiese AQTA model for China Mobile at WAIC.
- **Product Lifecycle:** Led competitor benchmarking and data labeling rules, closing the loop between algorithm training and user feedback.

Tencent Holdings Limited**Shanghai, China***AI Product Marketing Intern | Media & Public Relations Department**May 2025 – July 2025*

- **Quantitative and Qualitative Research:** Conducted cross-cultural research by virtue of 30+ interviews with parents/teenagers from diverse backgrounds and synthesized insights to inform inclusive strategies.
- **AI Product Marketing:** Designed a "short video + graphic" content strategy for Tencent Tools and boosted brand visibility via targeted storytelling.

Alibaba International Digital Commerce Group**Hangzhou, China***AI Operation Intern | AI Business Department**Mar 2024 – Sep 2024*

- **Industry Solutions:** Developed localization strategies for Taobao's key challenges in cross-border E-commerce. Implemented 6 localization strategies powered Taobao Global AI Multi-language version launch in Singapore.
- **SaaS Efficiency:** Managed AI-driven graphic marketing solutions for ICBU. Streamlined the "Requirement-Model-AB Test-Effect" pipeline, boosting SEO content production efficiency by 35%.

Xiaohongshu (Xingyin Information Technology Shanghai Co., Ltd.)**Shanghai, China***Commercial Operations Intern | Business Efficiency Department**Jan 2024 – Mar 2024*

- **Commercial Rules and Strategies:** Created a Standard Operating Procedure for MCN certification and disqualification. Optimized a rule engine to resolve false positives in cross-industry content governance and balanced compliance with user needs, reflecting empathy for marginalized creators.

Projects**SMG (Shanghai Media Group) - AIGC Special Project | AIGC Editor***Sep 2025 – Oct 2025***AI Short Film: AIGC Through 600 Years · From the Forbidden City to the Palace Museum**

- Led the end-to-end AI video production workflow, including script planning, historical data collection, AI image generation, historical fact verification, AI video creation, and final editing.
- Produced the AI featured film for SMG's "Forbidden City Centennial · Glory Across the World" special report, telling Chinese stories through innovative AIGC technology.

National College Student Innovation & Entrepreneurship Program | Team Leader*Sep 2023 – Jun 2024***Research on the Application of AIGC in Digital Design Industry-University-Research Innovation**

- Explored innovative expression of AIGC audio-visual content, mastered the AIGC production workflow for digital design and film & video creation, and had in-depth knowledge of the capability boundaries of domestic and international image/video AIGC models.
- Served as the visual designer for the AI album 24 Hours of the White Horse produced by Peking University; led the team to create AI short films Where Will You Be in 10 Years and SJTU 130th Anniversary Announcement.

Honors

"Challenge Cup" National Technological Works Competition	First Prize in China	Oct 2023
National 3D Digital Innovation Design Competition	First Prize in China	Dec 2022
National Electricity Innovation Design Competition	First Prize in China	Dec 2022
2022 China Virtual Reality Competition	First Prize in China	Nov 2022
Milan Design Week – Exhibition of Excellent Design Works (China)	First Prize in China	Jun 2023
National Energy Practice and Science & Technology Competition	First Prize in China	Aug 2023

Skills**Operational Skills**

- Activity Management: MS Office (Data Visualization and Data Tracking)
- Patents: 6 National Utility Model Patents (focused on tech-enabled social impact solutions)
- Publications: 3 Academic Papers on AI-Cultural Innovation Integration

Technical Skills

- Graphic Design & Video Editing: Adobe Software Package (PS, PR, AE, AI)
- AIGC: Chat GPT, Gemini, Seedance, Seedream, Qwen, Kling, Step Fun, TapNow
- Languages: Mandarin Chinese (native), English (fluent)
- IELTS 6.5, CET-4 600, CET-6 516

证明材料

一、获奖证书	1
(一) 国家级竞赛获奖及奖学金	1
2024-2025 学年国家奖学金、2022-2023 学年国家奖学金、2021-2022 学年国家奖学金	
全国大学生英语竞赛 全国特等奖	
第十八届“挑战杯”全国大学生课外学术科技作品竞赛 全国一等奖	
“米兰设计周”中国高校设计学科师生优秀作品展 全国一等奖	
全国三维数字化创新设计大赛年度总决赛（数字工业设计大赛） 全国一等奖	
第十六届全国大学生节能减排社会实践与科技竞赛 全国一等奖	
(二) 省级竞赛获奖及奖学金	7
2025 年“知行杯”上海市大学生社会实践大赛 特等奖	
第十届“汇创青春”上海大学生文创作品展示活动大赛 上海市一等奖	
第八届“互联网+”大学生创新创业大赛（高教主赛道）省金奖	
第十三届“挑战杯”中国大学生创业计划竞赛 省一等奖	
(三) 校级竞赛获奖及奖学金	13
二、科研成果	18
(一) 国家级大学生创新创业训练项目	18
《AIGC 赋能全链路数字设计产学研协同创新的应用研究》	
《吉林冰雪产业非遗文化交互平台设计应用》	
(二) 国家级期刊学术论文发表	22
《基于物联网技术的智能家居产品设计》	
《竖屏短视频的媒介景观影像建构研究》	
《数字互动艺术推动吉林冰雪文化场景呈现及传播研究》	
(三) 国家实用新型专利	25
三、实习实践	26
(一) 实习工作证明	26
字节跳动-剪映算法成片策略实习	
腾讯集团-市场与公关部实习推荐函	
阿里巴巴-数字国际商业集团实习	
(二) 项目实践证明	27
上海广播电视台 SMG 故宫百年专题《AIGC 穿越 600 年：从紫禁城到故宫博物院》AIGC 编辑	
上海交通大学 130 周年制作《上海交通大学建校 130 周年公告》AI 编剧、制作	
哔哩哔哩 2025 年毕业歌《我们都很棒》制片助理	
Step-Audio 2 Technical Report	

一、获奖证书

(一) 国家级竞赛获奖及奖学金

1.	2024-2025 学年	国家奖学金 (硕士)	获奖率 1.5‰
2.	2022-2023 学年	国家奖学金 (本科)	获奖率 1.5‰
3.	2021-2022 学年	国家奖学金 (本科)	获奖率 1.5‰
4.	2023 年	中国大学生自强之星	获奖率 0.1‰
5.	全国大学生英语竞赛		全国 特等奖
6.	第十八届“挑战杯”全国大学生课外学术科技作品竞赛		全国 一等奖
7.	米兰设计周-中国高校设计学科师生优秀作品展		全国 一等奖
8.	全国三维数字化创新设计大赛年度总决赛 (数字工业设计大赛)		全国 一等奖
9.	中国虚拟现实大赛		全国 一等奖
10.	第十六届全国大学生节能减排社会实践与科技竞赛		全国 一等奖
11.	全国大学生电力创新设计竞赛		全国 一等奖
12.	第三届全国学校冰雪创意设计大赛 (大学生组)		全国 二等奖
13.	中国大学生计算机设计大赛 (微课与教学辅助)		全国 三等奖
14.	中国大学生计算机设计大赛 (数媒静态设计专业组)		全国 三等奖
15.	中国大学生计算机设计大赛 (信息可视化设计)		全国 三等奖
16.	第十五届全国大学生节能减排社会实践与科技竞赛		全国 三等奖
17.	全国仿真创新应用大赛		全国 三等奖
18.	长三角数据开放创新应用大赛 (共同富裕赛道)		全国三等奖
19.	第九届“创青春”全国创新创业大赛 社会企业专项赛		全国 优秀奖
20.	第二十一届全国大学生英语演讲比赛		全国 优秀奖
21.	第十四届全国大学生英语风采比赛		全国 优秀奖
22.	中国大学生广告艺术节学院奖 (平面广告)		全国 优秀奖
23.	中国大学生广告艺术节学院奖 (广告文案)		全国 优秀奖
24.	中国大学生广告艺术节学院奖		全国 入围奖

(二) 省级竞赛获奖及奖学金

1.	2024 年	吉林省“优秀大学生”	获奖率 0.5‰
2.	2023 年	吉林省“优秀大学生”	获奖率 0.5‰
3.	2023 年	吉林省“大学生自强之星”	获奖率 0.15‰
4.	2020-2021 学年	吉林省政府奖学金	获奖率 4.5‰
5.	2022 年度	吉林市优秀共青团员	获奖率 1‰
6.	2021 年度	吉林市优秀共青团员	获奖率 1‰
7.	2025 年“知行杯”上海市大学生社会实践大赛		上海市 特等奖
8.	第十届“汇创青春”上海大学生文创作品展示活动大赛		上海市一等奖
9.	第十届“汇创青春”上海大学生文创作品展示活动大赛		上海市二等奖
10.	第十届“汇创青春”上海大学生文创作品展示活动大赛		上海市三等奖
11.	第八届吉林省“互联网+”大学生创新创业大赛 高教主赛道		吉林省 金奖
12.	第八届“创青春”吉林省创新创业大赛社会 企业专项赛 创新组		吉林省 金奖
13.	第十三届“挑战杯”中国大学生创业计划竞赛		吉林省 一等奖
14.	全国仿真创新应用大赛		吉林省 一等奖
15.	吉林省大学生虚拟现实大赛		吉林省 一等奖
16.	“哈希”第十七届全国环境友好科技竞赛		东北赛区一等奖
17.	“哈希”第十七届全国环境友好科技竞赛		东北赛区三等奖
18.	中国大学生计算机设计大赛（微课与教学辅助）		吉林省 一等奖
19.	中国大学生计算机设计大赛（数媒静态设计专业组）		吉林省 一等奖
20.	中国大学生计算机设计大赛（信息可视化设计）		吉林省 二等奖
21.	吉林省电子商务案例分析大赛		吉林省 二等奖
22.	上海高校实践育人创新创业“新青年·正当时”大学生融媒体作品大赛		上海赛区 二等奖
23.	米兰设计周-中国高校设计学科师生优秀作品展		吉林赛区 二等奖
24.	米兰设计周-中国高校设计学科师生优秀作品展		吉林赛区 三等奖
25.	第七届吉林省“互联网+”大学生创新创业大赛 高教主赛道		吉林省 铜奖
26.	第八届吉林省“互联网+”大学生创新创业大赛 产业赛道		吉林省 铜奖
27.	第十八届“挑战杯”吉林省大学生课外学术科技作品竞赛“红色专项”		吉林省 三等奖
28.	吉林省大学生虚拟现实大赛		吉林省 三等奖
29.	2022 年第十六届 iCAN 全国大学生创新创业大赛		吉林省 三等奖
30.	2021 年 iCAN 全国大学生创新创业大赛		吉林省 三等奖
31.	中美青年创客大赛		沈阳赛区 三等奖
32.	中美青年创客大赛		沈阳赛区 三等奖
33.	未来设计师·全国高校数字艺术设计大赛		吉林赛区 三等奖
34.	吉青总社杯·第三届吉林省青年新媒体创新创业大赛		吉林省 三等奖
35.	中国高校智能机器人创意大赛		吉林赛区 三等奖

(三) 校级奖学金及荣誉称号

- | | | |
|---------------------------|---|--------|
| 1. 2025 年度 | 北京大学人工智能赋能金融科技“研究生教育创新计划” | |
| 2. 2025 年度 | 北京大学具身智能与价值共创“研究生教育创新计划” | |
| 3. 2024-2025 年度 | ICCI Public Art Program-Studio of Ceative AIGC “优秀学生” | |
| 4. 2025 年 | 全球文化创意产业合作与发展国际会议“优秀志愿者” | |
| 5. 2025 年度 | 上海交通大学 优秀团员 | |
| 6. 2024-2025 年度 | 上海交通大学全球胜任力训练营“优秀营员” | |
| 7. 2021-2022 年度 | 东北电力大学优秀团员 2 次 | |
| 8. 2020-2023 学年 | 优秀学生标兵 3 次 | |
| 9. 2022-2023 学年 | 思源电气奖学金 | |
| 10. 2021-2022 学年 | 丰满发电厂奖学金 | |
| 11. 2020-2023 学年 | 优秀学生一等奖学金 6 次 | |
| 12. 2020-2023 学年 | 创新奖学金 4 次 | |
| 13. 2021-2023 学年 | 优秀学生干部 2 次 | |
| 14. 2022 届 | 优秀志愿者标兵 | |
| 15. 2021 年 | 优秀志愿者 | |
| 16. 2023 年 | 公益未来大学生就业力实践项目一等奖 | |
| 17. 2022 年 | 东北电力大学疫情防控志愿服务证书 | |
| 18. 2022 年度 | 东北电力大学“科技之星”个人奖 | |
| 19. 2022 年度 | 东北电力大学“科技之星”团队奖 | |
| 20. 2020 级 | 东北电力大学“学习筑梦班”“优秀学员标兵” | |
| 21. 2020 级 | 东北电力大学“学习筑梦班”“优秀班干部” | |
| 22. 外研社“沟通世界的国才·国际传播力”挑战赛 | | 校级 一等奖 |
| 23. “外研社·国才杯”全国英语阅读大赛 | | 校级 一等奖 |
| 24. “外研社·国才杯”全国英语写作大赛 | | 校级 二等奖 |
| 25. “外研社·国才杯”全国英语演讲大赛 | | 校级 三等奖 |

二、科研成果

（一）国家级大学生创新创业训练项目

1. 主持项目《盐域绿迹——基于限根栽培技术的智能化盐碱地改良方案》，第一负责人，中期阶段
2. 主持项目《AIGC 赋能全链路数字设计产学研协同创新的应用研究》，第一负责人，已结项
3. 主持项目《吉林冰雪产业非遗文化交互平台设计应用》，第一负责人，优秀结项
4. 参与项目《基于新能源的基站式风光互补智能植被护理装置研发》，第二负责人，已结项

（二）国家级期刊学术论文发表

1. 《数字互动艺术推动吉林冰雪文化场景呈现及传播研究》于《中国地市报人》第一作者
2. 《竖屏短视频的媒介景观影像建构研究》于《中国报业》第三作者（全国中文核心来源期刊）
3. 《基于物联网技术的智能家居产品设计》于《上海服饰》第三作者

（三）国家实用新型专利

- | | |
|------------------------|----|
| 1. 《一种摄影服务用摄影样品显示装置》 | 授权 |
| 2. 《一种自动修草护理装置及充电基站》 | 授权 |
| 3. 《一种用于风力发电机叶片覆冰监测装置》 | 授权 |
| 4. 《一种应用于逆风抗干扰的广角阵列喷嘴》 | 授权 |
| 5. 《一种风电塔筒爬行检修装置》 | 授权 |
| 6. 《一种风电塔筒爬行机械》 | 授权 |

三、实习实践

（一）实习工作证明

1. 阿里巴巴数字国际商业集团实习
2. 小红书-行吟信息科技（上海）有限公司实习
3. 国家能源集团国电环境保护研究所实习

（二）项目实践证明

1. 上海广播电视台 SMG 故宫百年专题《AIGC 穿越 600 年：从紫禁城到故宫博物院》AI 特约编辑
2. 上海市区校联动民间外交“海派绮梦·戏墨丹青”戏剧展主策展人
3. 文创学院十周年 AI 短片《十年后的你在哪儿》AI 编剧、制作
4. 上海交通大学 130 周年制作《上海交通大学建校 130 周年公告》制作
5. 哔哩哔哩 2025 年毕业歌《我们都很棒》制片助理
6. 中国管理科学研究院咨询部工程技术课题管理委员会课题成员
7. Step-Audio 2 Technical Report

一、获奖证书

(一) 国家级竞赛获奖及奖学金

2024-2025 学年国家奖学金



2022-2023 学年度国家奖学金



2021-2022 学年度 国家奖学金




2023 年“中国大学生自强之星”



全国大学生英语竞赛 全国特等奖



第十八届“挑战杯”全国大学生课外学术科技作品竞赛全国一等奖



米兰设计周 中国高校设计学科师生优秀作品展

全国一等奖



全国三维数字化创新设计大赛年度总决赛

(数字工业设计大赛) 全国一等奖



中国虚拟现实大赛 全国一等奖




“建行杯”第十六届全国大学生节能减排社会实践与科技竞赛

全国一等奖



全国大学生电力创新设计竞赛

全国一等奖



第三届全国学校冰雪创意设计大赛（大学生组） 全国二等奖



中国大学生计算机设计大赛

（微课与教学辅助）

全国三等奖



中国大学生计算机设计大赛

（数媒静态设计专业组）

全国三等奖



中国大学生计算机设计大赛

（信息可视化设计）


全国三等奖



第十五届全国大学生节能减排社
会实践与科技竞赛
全国三等奖



长三角数据开放创新应用大赛
(共同富裕赛道)
全国三等奖



第九届“创青春”全国创新创业
大赛 社会企业专项赛 全国优秀
奖



全国仿真创新应用大赛 全国三等奖



第二十一届全国大学生英语演讲比赛 全国优秀奖



第十四届全国大学生英语风采比赛 全国优秀奖



中国大学生广告艺术节学院奖（平面广告）

全国优秀奖




中国大学生广告艺术节学院奖（广告文案）

全国优秀奖




中国大学生广告艺术节学院奖全国入围奖 6 项



(二) 省级竞赛获奖及奖学金

2024 年吉林省“优秀大学生”



2023 年吉林省“优秀大学生”



2023 年吉林省“大学生自强之星”



2020-2021 学年度 吉林省政府奖学金





2022 年度吉林市优秀共青团员



2021 年度吉林市优秀共青团员



2025 年“知行杯”上海市大学生社会实践大赛 上海市特等奖



第十届“汇创青春”大学生文创作品展示活动大赛 上海市一等奖



第十届“汇创青春”大学生文创作品展示活动大赛 上海市二等奖



第十届“汇创青春”大学生文创作品展示活动大赛 上海市三等奖



第八届吉林省“互联网+”大学生创新创业大赛（高教主赛道）吉林省金奖



第八届“创青春”吉林省创新创业大赛社会企业专项赛（创新组）吉林省金奖



第十三届“挑战杯”中国大学生创业计划竞赛 吉林省一等奖



全国仿真创新应用大赛 吉林省一等奖



吉林省大学生虚拟现实大赛 吉林省一等奖



“哈希”第十七届全国环境友好科技竞赛
东北赛区一等奖



“哈希”第十七届全国环境友好科技竞赛
东北赛区三等奖



中国大学生计算机设计大赛
(微课与教学辅助)
吉林省一等奖



中国大学生计算机设计大赛
(数媒静态设计专业组)
吉林省一等奖



中国大学生计算机设计大赛
(信息可视化设计)
吉林省二等奖



吉林省电子商务案例分析大赛
吉林省二等奖



上海高校实践育人创新创业基地联盟“新青年，正当时”大学生融媒体作品大赛 上海赛区二等奖



米兰设计周 中国高校设计学科师生优秀作品展
吉林分赛区二等奖



米兰设计周-中国高校设计学科师生优秀作品展
吉林分赛区三等奖



第七届吉林省“互联网+”大学生创新创业大赛
高教主赛道 吉林省铜奖



第八届吉林省“互联网+”大学生创新创业大赛
产业赛道 吉林省铜奖



第十八届“挑战杯”大学生课外学术科技作品竞赛
“红色专项”活动 吉林省三等奖



吉林省大学生虚拟现实大赛 吉林省三等奖



2022 年第十六届 iCAN 全国大学生创新创业大赛
吉林省三等奖



2021 年 iCAN 全国大学生创新创业大赛
吉林省三等奖



中美青年创客大赛 沈阳赛区三等奖



中美青年创客大赛 沈阳赛区三等奖



未来设计师·全国高校数字艺术设计大赛 吉林分赛区三等奖



吉青总社杯·第三届青年新媒体创新创业大赛 吉林省三等奖




中国高校智能机器人创意大赛
吉林省赛区三等奖



(三) 校级奖学金及荣誉称号


2025 年度北京大学人工智能赋能金融科技

“研究生教育创新计划”



2025 年度北京大学具身智能与价值共创

“研究生教育创新计划”



ICCI Public Art Program-Studio of Ceative

AIGC “优秀学生”



2025 年全球文化创意产业合作与发展国际会议

“优秀志愿者”



2025 年度上海交通大学 优秀团员



上海交通大学全球胜任力训练营“优秀营员”



2022 年度东北电力大学优秀团员



2021 年度东北电力大学优秀团员



2022 学年优秀学生标兵



2021 学年优秀学生标兵



2020 学年优秀学生标兵



2022-2023 学年 思源电气奖学金



2021-2022 学年 丰满发电厂奖学金



2020-2023 学年 优秀学生一等奖学金 6 次



2022-2023 学年 创新一等奖学金



2021-2022 学年 创新二等奖学金



2021-2022 学年 创新三等奖学金



2020-2021 学年 创新三等奖学金



2022-2023 学年 优秀学生干部



2021-2022 学年 优秀学生干部



2022 届 优秀志愿者标兵



2021 年 优秀志愿者



2023 年 公益未来大学生就业力实践项目一等奖



2022 年 东北电力大学疫情防控志愿服务证书



2022 年度东北电力大学“科技之星”个人奖



2022 年度东北电力大学“科技之星”团队奖



2020 级东北电力大学“学习筑梦班”
“优秀学员标兵”



2020 级东北电力大学“学习筑梦班”
“优秀班干部”



外研社“沟通世界的国才·国际传播力”挑战赛
校级一等奖



“外研社·国才杯”全国英语阅读大赛
校级一等奖



“外研社·国才杯”全国英语写作大赛 校级二等奖



“外研社·国才杯”全国英语演讲大赛 校级三等奖



二、科研成果

(一) 国家级大学生创新创业训练项目

《盐域绿迹——基于限根栽培技术的智能化盐碱地改良方案》

2025 年国家级大学生创新创业训练计划项目（第一负责人，中期阶段）

“上海交通大学2025级大学生创业训练计划”项目立项答辩结果公示

“上海交通大学2025级大学生创业训练计划”

项目立项答辩结果公示

“上海交通大学2025级大学生创业训练计划”项目立项评审工作于2025年6月4日顺利完成。根据《国家级大学生创新创业训练计划管理办法》（教高函[2019] 13号）、《上海交通大学“双一流”本科人才培养双创实践体系项目管理细则》等文件要求，现将评审结果公示如下：

所属学院	项目名称	项目级别
南加州大学文化创意产业学院	盐域绿迹——基于限根栽培技术的智能化盐碱地改良方案	国家级实践项目
材料科学与工程学院	新一代航空发动机高温合金复杂超薄壁构件铸造解决方案研究	国家级实践项目
生物医学工程学院	微光智检——基于微纳光子学的术中炎症实时传感与闭环管理系统	国家级实践项目
医学院	骨病灶清除植骨机器人系统的开发与应用	国家级实践项目
医学院	灵境知行：基于数字人交互的思政、乡村与科普教育融合创新平台计划书	国家级训练项目
化学化工学院	蝶翼——新一代柔性 OLED 透明盖板膜	国家级训练项目
机械与动力工程学院	无人智能模块化甘蔗收获机	国家级实践项目
医学院	医知优选：AI驱动的医学科普视频质量评估	国家级训练项目
机械与动力工程学院	"Fungus"--主打跨学科合作创新的社交平台的制作与运营	市级实践项目

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

大学生创新创业训练计划管理系统



主页

选题管理

立项管理

中期管理

结题管理

项目异动管理

汇总查询

立项信息汇总

执行计划书汇总

周进展汇总

学期检查汇总

结题报告汇总

项目变更汇总

项目延期结题汇总

项目中止申请汇总

个人设置

列表

立项信息汇总 > 列表

批次: Nothing selected

项目编号: 项目编号

项目名称: 项目名称

项目类型: 请选择项目

项目级别: 请选择项目

项目状态: 请选择项目

第一主持人: 第一主持人姓名

第一主持人: 第一主持人姓名

第一主持人: 第一主持人姓名

执行期限: 请选择执行

指导教师: 指导教师姓名

指导教师: 指导教师姓名

指导教师: 指导教师姓名

每页显示: 20条

查询

重置

项目申报汇总表

大学生参与项目情况

列表显示设置

序号

项目编号

项目类型

项目级别

第一主持人

立项状态

操作

1

2025102480215

创业实践项目

国家级

詹雨萌(124270910042)

学校审核项目通过

当前页数: 1/1

共 1 条记录, 每页显示 20 条记录

《AIGC 赋能全链路数字设计产学研协同创新的应用研究》
2023 年国家级大学生创新创业训练计划项目（第一负责人，已结项）

2023 年国家级大学生创新创业训练计划 项目经历证明

兹证明：

东北电力大学詹雨萌，系艺术学院广播电视编导专业编导 202 班本科生，学号：2020315030216，身份证号：32010520020521022X。

该生于 2023 年 6 月起，担任第一主持人参与 2023 年国家级大学生创新创业训练计划项目，项目名称：《AIGC 赋能全链路数字设计产学研协同创新的应用研究》，项目编号：2023073，指导老师：路鹏，项目成员：詹雨萌、刘梦洁、邵丽娜、文亘、刘乃欣。

经高校审核，项目通过，已立项。

特此证明！



《吉林冰雪产业非遗文化交互平台设计应用》

2022 年国家级大学生创新创业训练计划项目（第一负责人，优秀结项）

国家级大学生创新创业训练计划平台

首页 历年项目 结项项目 年度进展报告 通知公告 咨询问答 证书查询

2022 年国家级大学生创新创业训练计划项目经历证明

兹证明：

东北电力大学詹雨萌，系艺术学院广播电视编导专业编导 202 班本科生，学号：2020315030216，身份证号：32010520020521022X。

该生于 2022 年 6 月到 2023 年 6 月，担任第一主持人参与 2022 年国家级大学生创新创业训练计划项目，项目名称：《吉林冰雪产业非遗文化交互平台设计应用》，项目编号：202210188077，指导老师：路鹏，项目成员：詹雨萌、孙昊彤、李佳纯、于晓、马丽。

经学院大创项目验收评审委员会认定，项目合格，已结项。

特此证明！



当前位置：首页 历年项目 学生查询 吉林冰雪产业非遗文化交互平台设计应用

项目编号:	202210188077																																																						
项目名称:	吉林冰雪产业非遗文化交互平台设计应用																																																						
项目类型:	创新训练项目																																																						
项目类别:	一般项目																																																						
重点支持领域:																																																							
所属学校:	东北电力大学																																																						
项目实施时间:	2022-06-01 至 2023-06-01																																																						
所属学科门类:	艺术学																																																						
所属专业大类:	戏剧与影视学类																																																						
立项时间:	2022-09-14																																																						
项目成员:																																																							
<table><tr><th>姓名</th><th>年级</th><th>学号</th><th>所在院系</th><th>专业</th><th>联系电话</th><th>E-mail</th><th>是否主持人</th></tr><tr><td>詹雨萌</td><td>*</td><td>2020315030216</td><td>*</td><td>*</td><td>*</td><td>*</td><td>第一主持人</td></tr><tr><td>孙昊彤</td><td>*</td><td>2020315040209</td><td>*</td><td>*</td><td>*</td><td>*</td><td>否</td></tr><tr><td>李佳纯</td><td>*</td><td>2020305020208</td><td>*</td><td>*</td><td>*</td><td>*</td><td>否</td></tr><tr><td>于晓</td><td>*</td><td>2021315030115</td><td>*</td><td>*</td><td>*</td><td>*</td><td>否</td></tr><tr><td>马丽</td><td>*</td><td>2019311100107</td><td>*</td><td>*</td><td>*</td><td>*</td><td>否</td></tr></table>								姓名	年级	学号	所在院系	专业	联系电话	E-mail	是否主持人	詹雨萌	*	2020315030216	*	*	*	*	第一主持人	孙昊彤	*	2020315040209	*	*	*	*	否	李佳纯	*	2020305020208	*	*	*	*	否	于晓	*	2021315030115	*	*	*	*	否	马丽	*	2019311100107	*	*	*	*	否
姓名	年级	学号	所在院系	专业	联系电话	E-mail	是否主持人																																																
詹雨萌	*	2020315030216	*	*	*	*	第一主持人																																																
孙昊彤	*	2020315040209	*	*	*	*	否																																																
李佳纯	*	2020305020208	*	*	*	*	否																																																
于晓	*	2021315030115	*	*	*	*	否																																																
马丽	*	2019311100107	*	*	*	*	否																																																
指导教师:																																																							
<table><tr><th>姓名</th><th>单位</th><th>专业技术职务</th><th>指导教师类型</th></tr><tr><td>路鹏</td><td></td><td>副教授</td><td>第一指导教师</td></tr></table>								姓名	单位	专业技术职务	指导教师类型	路鹏		副教授	第一指导教师																																								
姓名	单位	专业技术职务	指导教师类型																																																				
路鹏		副教授	第一指导教师																																																				

项目信息[收起]

负责人曾经参与科研的情况：

项目负责人詹雨萌：江苏省南京市人，女，东北电力大学艺术学院广播电视编导专业学生，校 2020 级“学习筑梦班”学员。现任编号 202 班学委、校 2020 级“学习筑梦班”宣传委员、社团联合会外联部副部长、纪录片研究小组成员、6-zone 工作室成员。

在科研方面，曾获吉林省政府奖学金、国家助学金、校优秀学生一等奖学金 3 次、校创新单项奖学金等，奖学金共 6 次，曾获“优秀共青团员”、“优秀学生标兵”、“优秀志愿者”等荣誉称号。在国家级期刊、综合性新闻理论月刊《中国地市报人》2022 年第 12 期第一作者身份录用论文一篇《数字互动艺术推动吉林冰雪文化场景呈现及传播研究》；在国家级教育类学术期刊、中国核心期刊《教育学文摘》发表论文 1 篇《点线面在不同现代体系绘画作品中的视觉符号表现及感染力》，实用新型专利授权 1 项、受理 3 项。

指导教师承担科研课题情况：

指导老师路鹏老师：东北电力大学艺术学院副院长，博士，硕士研究生指导教师。主持吉林省新文科研究与改革实践项目 1 项，其他省级教改项目 4 项，作为骨干参研省级教改项目 5 项；主持校级教改项目 3 项，参与校级教改项目 5 项；荣获省级教学成果奖三等奖 1 项，校级教学成果奖一等奖 1 项，三等奖 1 项；获吉林省教育技术成果奖一等奖 2 项；以第一作者发表教改论文十余篇。主持及参与省级科研项目 2 项、市级项目 7 项。围绕研究方向共发表研究论文三十余篇，其中 SCI/ET 检索文章 15 篇，CSSCI 文章 4 篇，中文核心 4 篇，其它高水平国际会议论文 2 篇。

指导教师对本项目的支持情况：

（一）创业条件：学校高度重视大学生创新创业实践活动，指导老师提供相关的创新创业支持，在学校公众号和官方网站上都会及时发布创新创业实践活动和比赛的最新资讯；此外，学校不仅设立了专门的创新创业实践基地，比如艺术学院创客中心等，而且为大学生创新创业实践活动提供了诸多的扶持政策以及配套资金。

（二）技术条件：团队成员所在的 6-ZONE 数字创意工作室可作为项目创新创业基地，提供硬件支撑和实验基地，包括摄影设备器材、机械存储硬盘等硬件设施上的支持，院校师资力量雄厚，指导老师给予学生及时专业的技术指导，拥有强大的研究实力。

（三）资料条件：纸质和数字图书馆可提供团队所需的参考资料；指导老师可以提供相关的设备以供参考。

（四）教师条件：指导老师路鹏老师，在数字媒体领域取得了一些重要的研究成果，这些经验和成果为本课题的研究奠定了基础，具有较高学术研究实力及丰富的学生创新创业指导经验，在项目遇到困难时，指导老师将为团队提供专业技术指导。

项目简介：

项目着眼于北方冰雪民俗文化及民俗非遗项目的传承与发展，通过全新的推广思维和引导方式，让更多的人能够更加近距离地接触到真正的东北非遗文化，也让更多的人能够真正了解到北方地区“不一样的冰雪民俗文化”，把握冰雪文化的“核心”，结合互联网+背景下的科技及交互优势，有效推进各民族冬季民俗文化及民俗娱乐项目的挖掘与传承，提升整体冬季民俗文化的基础质量，让更多的人能够通过实践与视觉充分感受现实冬季民俗文化的美和不同民族艺术的美。1.数字互动艺术创新多重表达，助力吉林冰雪文化产业：冰雪文化产业的场景呈现与传播推广工作近年来迅速发展，为了打破时间、空间的局限性，让人们更深入、更切实地走近冰雪文化，本项目利用数字互动艺术推动冰雪文化场景呈现。2.吉林冰雪文化传播推广策略，拓展传播新渠道及形式：项目平台把东北冰雪文化传承和相关的娱乐项目发掘作为构建和衔接未来轨道的关键一轴，以完善化的实践娱乐活动设计、实践、挖掘和文化传播为工作重心，促进冰雪和东北各民族民俗文化之间的深度融合，推动地区冰雪文化与冰雪娱乐的传播与创新传承发展。

《基于新能源的基站式风光互补智能植被护理装置研发》
2022 年国家级大学生创新创业训练计划项目（第二负责人，已结项）

2022 年国家级大学生创新创业训练计划
项目经历证明

兹证明：

东北电力大学唐雨萌，系艺术学院广播电视编导专业编导 202 班本科生，学号：2020315030216，身份证号：32010520020521022X。

该生于 2022 年 6 月到 2023 年 6 月，参与 2022 年国家级大学生创新创业训练计划项目，项目名称：《基于新能源的基站式风光互补除草装置研发》，项目编号：202210188045，指导老师：郝德成，项目成员：杨明皓、唐雨萌、高涵、许坤、李文婧。

经学院大创项目验收评审委员会认定，项目合格，已结项。

特此证明！



国家级大学生创新创业训练计划平台

首页 历年项目 结项项目 年度进展报告 通知公告 咨询问答 证书查询

当前位置：首页 历年项目 学生查询 基于新能源的基站式风光互补除草装置研发

项目编号：202210188045

项目名称：基于新能源的基站式风光互补除草装置研发

项目类型：创新训练项目

项目类别：一般项目

重点支持领域：

所属学校：东北电力大学

项目实施时间：2022-06-01 至 2023-06-01

所属学科门类：工学

所属专业大类：电气类

立项时间：2022-09-14

项目成员：

姓名	年级	学号	所在院系	专业	联系电话	E-mail	是否主持人
杨明皓	*	2020302010305	*	*	*	*	第一主持人
唐雨萌	*	2020315030216	*	*	*	*	否
高涵	*	2021307040113	*	*	*	*	否
许坤	*	2021301020109	*	*	*	*	否
李文婧	*	2021301020205	*	*	*	*	否

指导教师：

姓名	单位	专业技术职务	指导教师类型
郝德成		实验师	第一指导教师

项目信息(收起)

负责人曾经参与科研的情况：

十五届“六百光年杯”节能减排大赛 国家三等奖，校一等奖
全国大学生计算机设计大赛 吉林赛区一等奖
“高教社杯”全国大学生数学建模大赛 吉林赛区省二等奖
第八届“互联网+”全国大学生创新创业大赛 校一等奖
第三届“光华杯”吉林省电子商务案例大赛 省二等奖、校一等奖
全国大学生电工数学建模大赛 二等奖
全国大学生“创新、创意、创业”电子商务大赛 吉林赛区三等奖、校一等奖
Mathercup数维杯 全国二等奖

指导教师承担科研课题情况：

基于开放式工程训练的大学生双创能力培养教学研究 论文
基于关键能力培养的开放式工程训练教学体系研究与实践 论文
机械合金化制备Ti-2SnC粉末 论文
提高数控车削加工教学效果的探讨 论文
基于逆向工程的汽轮机叶片型面CAD建模方法的研究 论文
多样化人才培养模式下的实验教学改革研究与实践 论文
第三届全国大学生工程训练综合能力竞赛 吉林赛区一等奖
第五届全国大学生工程训练综合能力竞赛 吉林赛区二等奖
2017第七届全国大学生机械创新设计大赛吉林赛区一等奖
2018全国三维数字化创新设计大赛吉林赛区一等奖
2019年全国三维数字化创新设计大赛国赛二等奖
2019吉林省高校大学生工程训练综合能力竞赛 吉林省一等奖
2020第九届全国大学生机械创新设计大赛 吉林省二等奖
2020全国高校教师教学创新大赛国赛二等奖
2020第十三届全国大学生节能减排社会实践与科技竞赛 国赛三等奖
2020第三届全国大学生可再生能源科技竞赛 国赛一等奖
2021 第四届中国高校智能机器人创意大赛 国赛一等奖
2021第十四届中国大学生计算机设计大赛 国赛二等奖

指导教师对本项目的支持情况：

本项目以绿色环保为出发点，符合国家提出的双碳战略目标，项目实施力求探索解决电动农业机械的智能化无人操作问题，立意新颖、切合实际。

项目简介：

传统除草机主要以汽油机、柴油机作为动力来源，存在耗能高、污染性强、噪声大、安全性能低等不足。为此团队独立设计出装置本体即除草小车，使用清洁可再生能源作为动力来源，电动机代替汽油机柴油机作为执行部件，此外采用机器视觉识别和GPS导航系统使小车能够实现无人化作业；同时参考加油站的外观原理，设计出装置基站即供电储能桩，充分利用风能补光能互补解决了电能供电的能源来源问题，利用机液流电池解决了储能问题。通过风光互补供电基站的电力输送保证用电需求，多余电能储存在由机液流电池构成的储能装置中，从而达到了节约能源、减少碳排放的作用。

(二) 国家级期刊学术论文发表

《数字互动艺术推动吉林冰雪文化场景呈现及传播研究》

发表于国家级期刊《中国地市报人》2023年第1期(第一作者),中国知网检索



凝心聚力担使命 奋楫扬帆新征程
从中国新闻奖作品看媒体精品生产
本刊向全国媒体征集摄影、美术作品(本期封面图片来源新华社)



传媒研究
克拉玛依日报社特约

Column

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

2023
总第433期

01

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

克拉玛依日报社特约

DOI: 10.16763/j.cnki.1007-4643.2023.01.026

数字互动艺术推动吉林冰雪文化场景呈现及传播研究

吉林冰雪文化场景呈现及传播研究

唐雨萌 路 鹏 田一然 孟禹杉 杨子琪

【摘要】冬奥会后,冰雪产业作为吉林省特色冰雪资源开发而形成的独特经济产业,吉林冰雪文化产业发展中拥有社会、政府、经济三方面的优势,同时也存在面临时代发展与新媒体冲击下的困境。数字互动艺术及新媒体技术为吉林冰雪文化产业发展提供新的可能性,分析吉林冰雪文化产业发展现状,展望冰雪产业应用新媒体技术多元化发展的未来趋势,具有重要意义。

【关键词】冰雪文化;数字互动艺术;新媒体传播

吉林省拥有冰雪文化的地域性优势,蕴含独特的冰雪文化魅力。数字互动艺术是影像与交互手段于一体的艺术表现形式,现已成为冰雪文化发展的新生力量。

吉林省立足于冰雪文化产业发展优势,亟待改善冰雪产业面临的问题,新兴发展的数字互动艺术将为吉林冰雪文化产业发展与传播,延伸冰雪文化产业链提供一条新思路。在冰雪文化中国化构建的东风之下,大力发展民族冰雪产业,吉林冰雪文化产业发展可以抓住冬奥会的契机实现升级。

一、冬奥会背景下吉林冰雪文化产业发展现状

(一) 吉林冰雪文化产业发展现状

1. 时代发展机遇与国家政策支持

2022年年初成功举办冬季奥林匹克运动会,冰雪文化受到了大众的关注与喜爱,逐渐成为国民经济体系的新兴产业与吉林省区域经济发展的增长点。冰雪文化产业发展近年来呈现良好发展态势,我国将冰雪文化作为国家经济发展的重点,党和国家高度重视冰雪文化产业发展。

冬奥会的冰雪产业聚集效应强大,借助新媒体打造新的冰雪运动活力平台,以逐步增强我国冰雪文化领域的话语权。

2. 经济因素与地域特色优势

我国冰雪旅游产业主要分布在东北三省,并逐步向华北、新疆、内蒙古、四川等地区拓展延伸,而各地的冰雪产业都有自己独特的特色。吉林省作为冰雪文化建设的重点地区,凭借优越的地理条件,拥有冰雪资源丰富的特色地域。

优势,正重点打造冰雪产业集聚区、推进冰雪丝路建设。

(二) 吉林冰雪文化产业发展困境

1. 后疫情时代与产业同质化

2020年以来,受到疫情影响,吉林冰雪文化产业发展信心造成冲击,在一定程度上对吉林冰雪文化产业发展形成了限制和阻碍。与此同时,产业发展同质化,使得吉林冰雪文化产业发展难以发挥,发展动力难以生成。因此,差异化协同发展而发挥吉林冰雪文化产业的比较优势,打造独具吉林地域特色的冰雪产品体系,避免产业同质化竞争,成为势在必行之发展之路和内在动力。

2. 碎片化传播与影响力弱化

由于冰雪产业具有季节性地域性较高的局限性,吉林省拥有冰雪产业开发优势,对于人口较多而更为广阔的南方地区来说,冰雪文化的传播具有区域性局限。吉林可以借助数字互动艺术打造智慧冰雪系统,构建“互联网+冰雪文化+服务升级”新模式,吸引更多广大受众加入到热爱冰雪文化的行列中。

与此同时,新媒体信息时代也存在生产内容碎片化、分散化、浅薄化的传播特征,使得传统信息的完整性叙事被削弱,深度思考和深入理解变得困难。故而,吉林冰雪文化产业可以借助现代化信息管理体系和新媒体传播理念与技术,实现信息传播、文化建设和业务资源数字化、网络化、标准化的统一管理,助力冰雪产业转型升级。

二、数字互动艺术在冰雪文化场景呈现中的应用

2023年第1期/总第433期

85

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

乡村振兴 Column

在乡村大地走出新闻“四力”

——苏州日报“看新时代苏州农村党建·走百村”融媒新闻行动分析

王乐飞

【摘要】2021年,在庆祝中国共产党成立100周年之际,江苏苏州日报报业集团开展了“看新时代苏州农村党建·走百村”大型融媒新闻行动,立足媒体融合改革的时代新命题,跳出“一纸一报”,深入“一镇一村”,依托苏州日报官方新闻客户端引流App,通过短视频、H5、网络海报、直播等多种线上形式,结合访谈、座谈会、论坛等多种线下活动,多维度、全媒体呈现“党建+”引领下苏州乡村振兴的大势。

【关键词】走百村;线上线下;媒体融合

苏州素有“鱼米之乡”的美誉,“三农”工作一直走在江苏乃至全国的前列。近年来,随着“乡村振兴”战略的持续推进,“鱼米之乡”在新时代焕发出新光彩,这座“新闻富矿”成为媒体关注的重中之重。

2021年,在庆祝中国共产党成立100周年之际,江苏苏州日报报业集团策划实施了“看新时代苏州农村党建·走百村”融媒新闻行动(以下简称“走百村”行动),在苏州全市选取100个村(涉农社区)作为样本,20多位年轻记者走进田间地头,深入农村一线,采掘“带露珠”的新闻。

与以往类似的主题新闻报道不同,苏州日报报业集团

在新时代,新的技术条件下,能够不断适应变化的环境,从而形成新的形式。冰雪场景数字化促进吉林冰雪文化多元化发展。数字互动艺术具有与生俱来的超越性与先锋性,有利于改善东北冰雪娱乐项目和民俗文化的劣势地位,发掘吉林优秀民间冰雪文化、历史文物资源,打造中华冰雪文化名片,打造冰雪文化背景下全新的民俗娱乐项目公益挖掘与定制化文化IP,实现可持续发展。

在此基础上,数字互动艺术融合吉林冰雪文化可以以创新冰雪文化与民俗娱乐项目融合为中心,建立东北民俗娱乐项目设计挖掘与传承新模式,树立吉林冰雪文化品牌,融文化资源开发与开发、设计与共享以及最终构建完成一体化创新平台。为此,实现冰雪文化在数字互动艺术中的创新中传承,在传承中创新,并实现冰雪文化与传统记忆深度融合,唤起大众对冰雪民俗传统的美好的记忆,从人文时空角度挖掘冰雪产业的亲和力。

结语:

数字互动艺术借用了人工智能与数字交互等新型技术手段,思维模式与表现模式,让创作者、作品、观众之间多端互动,将整个冰雪产业价值链转型升级为开放的互动

状态,在冰雪产业新型文化场景构建中具有深远价值与现实意义。“带露珠”的场景数字化是释放吉林省冰雪文化优势,全力推进冰雪文化数字化升级的关键一环。

数字互动艺术通过搭建情景化沉浸式的体验环境,让受众能够置身其中,从而降低受众文化学习与传播门槛,结合互联网与新媒体背景下的科技交互优势,有效推进各民族冬季民俗文化与民俗娱乐项目的挖掘与传承,让更多的人能够充分感受现实冬季民俗文化的魅力,冰雪文化的热情,冰雪旅游文化的激情。

参考文献:

[1] 王乐飞. 长春市冰雪体育旅游产业的现状与发展策略[J]. 吉林体育学院学报, 2016.

[2] 金永超. 李爱珍. 吉林省冰雪文化特色及相关产业发展对策研究[J]. 吉林广播电视大学学报, 2012, 26(10): 5-8.

[3] 田一然. 新媒体背景下吉林省冰雪文化产业的科技交互优势[J]. 吉林广播电视大学学报, 2016, 30(10): 39-44.

[4] 田一然. 新媒体时代文艺创作的本质——以《甄嬛传》为例[J]. 文艺与时代, 2014(10): 25-27.

(作者单位: 东北电力大学艺术学院)

编辑: 姜明强

《竖屏短视频的媒介景观影像建构研究》

发表于全国中文核心期刊 (2008 版)《中国报业》2024 年 1-2 月 (第三作者)，中国知网检索



学科视野 | Yue Ke Shi Yi

DOI:10.13854/j.cnki.cn11-2024.02.107

竖屏短视频的媒介景观影像建构研究

● 杨 鹏 苏一闻 詹雨萌



[摘要]数字媒介时代，竖屏短视频已经成为群众喜爱的社交、娱乐以及消费平台。随着竖屏短视频的流行，其媒介景观影像建构也成为了一个值得关注和研究的课题。在用户黏性增强、媒介技术与传播方式的变革、流量变现的商业价值等多重因素推动下，用户集聚的互动景观影像得以形成。在此背景下，媒介受众双方应保持对媒介景观的良好观察，以更好地推动竖屏短视频向好发展。

[关键词]竖屏短视频 媒介景观 景观呈现 景观成因 **[中图分类号]** G22 **[文献标识码]** A

近

年来，移动互联网的不断革新和移动智能手机的普及，都促使着传播媒介不断进步。在此背景下，移动短视频呈现并崛起式发展态势。由于智能手机用户使用习惯和媒介场景的改变，短视频比例也随之改变，短视频的衍生品——竖屏短视频应运而生。

竖屏短视频的发展现状

最早的竖屏影像可以追溯到1894年由法国人艾蒂安·朱尔·马雷拍摄的《马车的轮》。在传统影视制作的比例格式中，16:9在业界被认为是标准的影像制作格式。随着智能手机的普及和媒介技术的不断发展，手机成为生活娱乐的必需品。2016年后，随着抖音、西瓜视频等App上线，移动端短视频迅猛发展，竖屏短视频凭借聚焦主体的小景别构图、平民化的叙事视角等深受大众喜爱，并积累了大量的用户。根据中国互联网信息中心发布的第51次《中国互联网络发展状况统计报告》显示：截至2022年12月，我国短视频的用户为10.12亿，用户使用率达94.8%。在如此庞大的用户群体下，竖屏短视频呈现出全新的媒介景观影像。

竖屏短视频的媒介景观影像呈现

1.媒介景观理论

20世纪80年代，居伊·德波在其所著《景观社会》一书提

230 | 中国报业 | 2024.01(下)

出“媒介景观”理论。他认为景观是一种社会关系且现代社会景观为景观的放大堆积。受到德波的影响，道格拉斯·凯尔纳认为景观是“能体现现代社会基本价值观念，引导个人适应现代生活方式，并弥合现代社会中的冲突和解决方式”的媒介文化现象。

2.用户集聚的互动景观影像

竖屏短视频门槛低、碎片化、去中心化的传播模式深受用户喜爱，他们在竖屏短视频平台上基于不同的兴趣、情感等不断建立联系并不断聚集，呈现出群体化特征。使其用户黏性也不断增强。根据Quest Mobile发布的《2022年中国移动互联网年度报告》显示，短视频是用户时长占比最高的应用，其总用户时长占比达到28.5%。无论是物理环境还是虚拟环境，交流与沟通的分享都离不开人与人的互动。在竖屏短视频中，传受双方相互作用、相互影响，传受双方可以通过自己或他人发布作品并根据自己的喜好点赞、评论、转发。在传受过程中，双方不仅能够观看景观，也能够形成双向互动的互动景观。

例如，疫情过后，全国文旅行业逐渐复苏，各地文旅局长都想将自己家乡的美景、美食等通过积极宣传推广促进本地区文旅产业的迅速复苏。湖北随州、黑龙江塔子河、四川遂宁等地文旅局长的“变装”出镜，各省市、州、县文旅局长也不甘示弱，形成了文旅局长的“内卷”景观。

3.不同地域下的文化景观影像

德波认为：景观并非一个图像合集，而是通过图像中

介建立的人与人之间的一种社会关系。在竖屏短视频的传播过程中，其不仅承载着社会关系，也体现着自身的文化语境。从文化地理学角度讲，“景观”是意识形态、表征和意义世界为一体的概念。

例如，各地文旅局纷纷挑选具有丰富文化的景观，拍摄宣传视频。四川省甘孜州文旅局局长刘洪滨穿民族服饰，甘孜州道孚县文旅局局长陈泽宇化身身骑白马、戴天冠、唐明皇等多种角色等，带领观众体验不同地域独特的景观风貌和风采文化，唤醒了埋藏在大众心中的文明记忆。德国学者扬·阿斯曼在《文化记忆》一书中曾指出，每种记忆既面对过去又立足于当下，文化记忆也会随着时代变化而不断被重组，并诠释出新的文化机制。在每一阶段都能根据主题和价值形成群体的自我认同。

4.资本推动下的消费景观影像

竖屏短视频在满足用户观看多元化、个性化需求的同时，还要在资本推动下其商业价值。竖屏短视频的变现模式包括流量变现、直播带货、广告植入等等。德波以“景观即商品”揭示出当代社会存在的主导本质。在景观社会语境下，经济收益者借助媒介，并在他们的精心打造下景观影像潜藏着许多的商业符号。这些商业符号生产带有一定的目的性，是为了刺激受众消费和满足自己经济需要而存在的景观影像。

竖屏短视频的景观影像成因

1.门槛下方用户黏性增强

媒介技术的不断改进和普及，使得竖屏短视频的生产成本大大降低。随着创意和创作门槛的进一步降低，平台内容也更加丰富多样。竖屏短视频的门槛低主要表现在创作门槛低、技术门槛低以及观看门槛低三方面。首先，在创作过程中，创作者无需使用昂贵的拍摄设备，使用自己的智能手机即可完成拍摄，且可以随时取材、制作。其次，剪辑、特效等手机剪辑应用的推出，为创作者提供了手机客户端一站式剪辑服务。这些新媒体剪辑软件中包含着诸多精美的视频模板、丰富的音乐资源、多种风格字体等许多素材供创作者免费使用。最后，在传播过程中，竖屏短视频的信息传递更为集中且简洁易懂，能够更好吸引人们的注意力。同时，在互联网技术的支持下，受众可以使用自己的智能手机随时随地观看。

2.媒介技术与传播方式的变革

从最初以口头语言为媒介进行传播，到今天的数字传播媒介，是技术的不断革新推动着传播媒介的进步。因此，媒介不仅是联系社会的纽带，还是公众从事文化创造的工作。

具。媒介环境的改变影响着公众接收信息的方式，塑造了群众的世界观和审美趣味，而这些影响又反过来作用于公众的文化创造活动。早期以报刊、广播、电视等形式为主的传统媒体，只能依靠各媒体在固定时间进行信息传递。而在竖屏短视频中，人人都可以是创作者，群众可以利用手机随时即拍即发，让信息获取和传递更加快捷和广泛，也使人们获得信息和娱乐的速度大大增加，促进了媒介景观的快速发展和变化。

3.流量变现的商业价值

在景观社会中，商品经济的繁荣是景观的重要驱动力。随着新媒体技术的不断发展，抖音、快手等头部短视频平台，皆从最初的简单的日常分享发展到了今天集分享、直播、网购于一体的商业生态链。为迎合线上购物趋势，新媒体平台纷纷通过“直播+带货”融合的方式，搭建消费场景，使消费者在精美制作的视频中沉迷。

结语

竖屏短视频的景观影像在用户黏性强、媒介技术变革和资本力量的多种因素推动下产生了用户集聚的互动景观影像。我们不能忽视部分创作者打“擦边球”的情况，更不能利用虚假景观欺骗用户情感，导致景观异化。同时，媒介传受双方都应保持良好的媒介素养，以更好地推动竖屏短视频发展。

[参考文献]

(作者单位：东北电力大学艺术学院)

[1]参考文献

[1]中国互联网信息中心.第51次《中国互联网络发展状况统计报告》[R/OL].<https://www.cnnic.net.cn/h4/2023/03/03/08-10757.html>.

[2][法]居伊·德波.景观社会[M].北京:中国美术学院出版社,2016.

[3][美]詹姆斯·凯尔纳.媒体景观——当代美国社会文化透视[M].北京:清华大学出版社,2003.

[4]袁世伟.媒介文化地理学视域下电影中景观空间的视觉表述[J].电影评论,2021(14).

责任编辑：唐 斌

中国报业杂志社
CHINA NEWSPAPER INDUSTRY

稿件预录用通知

杨 鹏 苏一闻 詹雨萌 同志：

您的论文《竖屏短视频的媒介景观影像建构研究》，经初审同意预录用，将在《中国报业》2024年1-2月刊登。论文发表后寄给作者该期杂志2册。

《中国报业》杂志是由中国报业协会主办的新闻传播类核心期刊，是全国中文核心期刊（2008版）。国内统一刊号：CN11-4629/G2；国际刊号：ISSN1671-0029；邮发代号：82-300。



■ 请勿一稿多投，稿件文责自负。
■ 本刊有权对来稿进行删改，如有异议，请及时通知本刊编辑部。
■ 稿件使用费说明：本刊已许可中国知网以数字化方式复制、汇编、发行、信息网络传播本刊全文。
所有署名作者向本刊提交文章发表之行为视为同意上述声明。如有异议，请在投稿时说明。

《基于物联网技术的智能家居产品设计》

发表于国家级期刊《上海服饰》2024年7月（第三作者），中国知网检索

上海服饰

SHANGHAI FUSHI

2024年7月

第1期 总第315期

SHANGHAI FUSHI

2024年7月

第1期 总第315期



（二）智能的处理能力

智能产品不仅能实时捕捉并识别周围环境的变化，还能对捕捉到的信息进行分析和处理，从而做出更加智能、精准的决策或反应。为用户提供更加智能化、高效化的服务。例如，小米智能音箱 XiaoAI 能识别人的语音指令并转化为数字信号，从而控制其他联网设备的产品。其搭载了人工智能和百度深度学习人工智能应用系统 DuerOS，能识别不同的人工智能来解决不同难度的问题，更高效、更精准、更简洁。

（三）自然的交互方式

随着科技的进步，产品的技术也日益复杂，导致了操作和交互界面的复杂性增加。因此，探索更为自然流畅的交互方式是服务用户的必然选项。自然交互方式的概念首先起源于人机交互的研究领域，即所谓的自然用户界面。它基于用户最自然的操作方式，如动作、手势、语言等来操作计算机、控制鼠标和键盘的电脑。AI Pin 如图2所示，它通过去中心化语音指令来控制，没有电子屏幕，而是利用激光投影将显示界面投射到手掌上。其内置 AI 模型，能用语言进行交互、对话和检索信息。



图2 AI Pin

三、物联网技术下智能家居产品设计发展趋势

（一）注重产品的隐私性保护

智能家居产品最被争议的问题就是安全隐私。只有更完善地解决这一问题，智能家居产品的发展才会顺利。智能家居产品涉及用户的大量个人信息、生活习惯，甚至敏感数据。这些敏感信息一旦泄露、存储、处理或滥用，将侵犯用户的隐私权。作为产品设计师，智能家居的隐私性保护应融入

设计全过程，设计清晰的隐私政策，提供用户控制权，如数据访问、修改、删除等选项。同时，产品应设计有容错机制，确保即便在不当操作发生时，也能在各种复杂多变的环境下保持安全可靠运行状态。

（二）注重产品的实用性设计

产品的功能的实用性直接决定了产品的竞争力。当今市场很多产品为了追求“智能”而堆砌很多无用功能，增加了资源浪费。注重产品的实用性设计意味着在产品开发过程中优先考虑产品的功能性和用户体验，确保产品能满足用户的实际需求，解决用户的问题，并提供便捷、高效的使用体验。

（三）注重用户情感需求设计

当产品或服务能满足用户的情感需求时，他们会更加满意。进而增强他们对产品的忠诚度。用户情感的满足需要在人性化方面加强考虑，排除功能、造型、色彩等方面，人性化还需要在心理、体验和交互上下功夫。在体验方面用户的情感与操作的复杂性成正比。智能家居系统的控制界面过于复杂，会极大地降低用户的使用意愿和满意度。通过简化产品界面设计，降低用户的学习成本，能有效简化操作流程的复杂性。在心理方面，智能产品的人性化设计需要考虑用户的情感需求、安全感、归属感等多个因素，以确保产品与用户建立积极的情感联系。在交互方面，需要考虑用户习惯与行为、情感化设计等方面，满足用户的期待和习惯。

（四）注重资源的整合

在智能家居领域，产品设计正逐步向更加智能化、集成化的方向发展。其中，注重资源的整合已成为智能家居产品设计的大趋势。将各种硬件设备、软件平台等进行有效集成和优化配置，形成一个协同工作、高效运转的智能系统，以此实现资源的最大化利用，多样化的智能家居平台现状使不同产品间的兼容与互联互通面临挑战，从而增加了用户操作层面的复杂性。确立行业内统一的规范标准是核心所在，能造成产品间的广泛普及性。未来，随着技术的不断进步和市场的日益成熟，资源整合将在智能家居领域发挥更加重要的作用。

（五）注重个性化差异设计

智能家居产品的设计应考虑用户需求的个性化，包括年龄层次、身体特征、审美偏好等多重因素。从而为用户提供个性化服务体验。面向年轻群体，智能家居产品应侧重于实用性、舒适度；针对儿童用户，产品则需融入娱乐与趣味元素，寓教于乐，展现现代科技的魅力。又积极塑造儿童正确的价值观。而对于老年人群，产品则应定位为贴心的健康伴侣，

66 Design Context 设计文萃

基于物联网技术的智能家居产品设计

□ 路 鹏、杨金波、詹雨萌

摘要：在信息化时代，物联网被视为信息科技的重要组成部分。近年来已引起了产品设计的普遍重视。本文首先阐述了物联网、智能家居产品的相关概念；其次，从现有的物联网技术下智能家居产品的特点出发，分析物联网技术下智能家居产品的设计发展趋势；最后，归纳出物联网技术下智能家居产品的设计原则，以期为用户提供更智能的家居生活。
关键词：物联网；智能家居；设计原则
分类号：TB472；TP18

为创造一个更优质、更便捷的互联网、数字化和智能化的生活空间，众多的智能家居产品已经进入市场。然而，在设计和使用智能家居时，需要清楚地理解其特性。明确设计师应遵循的物联网下智能家居产品的设计原则，以跟随科技进步中人们的需求变化，做好每一个设计环节。只有这样，才能更有效地促进物联网环境下智能家居产品的设计发展，让智能家居产品更好地融入现代生活，为民众生活质量的提升与科技服务的提升打下坚实基础。

一、物联网、智能家居产品的概念

（一）物联网概念

物联网（Internet of Things）的概念最初来源于美国麻省理工学院（MIT）在1999年建立的自动识别中心（Auto-ID-Center）提出的网络无线识别（RFID）系统，即把所有物品通过射频识别等信息传感技术，与互联网连接起来，从而实现智能化识别和管理。经过信息化技术的发展，当前物联网技术的概念已经延伸为智能物联网。2020年中国智能物联网（AIoT）白皮书中指出：AIoT是人工智能与物联网的协同应用。它通过IoT系统的传感器实现实时信息采集，而在终端、边缘或云进行数据智能分析，最终形成一个智能化生态体系。在AIoT的架构中，IoT扮演着基础支撑的角色，其遍布各处的传感器和智能终端构成了强大的网络，实现了人类、机器与物体的紧密相连。

上海服饰·2024年7月

中国知网 <https://www.cnki.net>

Design Context 设计文萃

67

Design Context 设计文萃

68

不仅持续监测健康状态，还能在紧急关头迅速响应，提供及时的求助功能。未来，随着技术的不断进步和市场的日益成熟，个性化差异设计在智能家居领域将发挥更加重要的作用。

四、物联网技术下智能家居产品设计原则

（一）安全性原则

智能家居设备在设计及制造过程中，应确保系统具备强大的防御能力，以有效抵御黑客的恶意攻击，保障用户数据的安全与隐私。智能家居网络完全依赖于网络技术来确保信息的安全性。通过访问控制技术来限制对网络资源的非法访问和使用。同时，还依赖于防火墙技术和协议来保护网络通信和数据传输的安全。作为设计师，在设计智能家居产品时必须充分重视用户隐私权，通过最小化数据收集、确保数据仅用于授权目的并透明化数据处理流程等措施，构建以用户为中心的隐私保护机制，让用户安心享受智能家居带来的便利。

（二）体验性原则

智能家居产品深度融合前沿技术，实现了家居设备间的无缝互联与智能化管理。通过应用AI技术，智能家居系统能学习并理解用户的日常生活习惯与偏好，自动调整家居环境，如根据用户的作息时间自动调整室内光线、温度与音乐，营造最适宜的生活氛围。而且，智能家居产品注重交互体验的便捷性。无论是通过智能手机App的远程控制，还是采用先进的语音识别技术，都能让用户以最简单直观的方式与设备进行交互，实现一键控制家中各类设备。

（三）一致性原则

一致性原则要求产品在多个方面保持统一性和连贯性。不同的产品模块之间应保持一致的设计风格和设计逻辑。可以从产品设计、操作界面与交互设计等层面保持一致。首先，在视觉层面，智能家居产品应追求颜色、风格、属性等视觉元素的一致性；其次，在行为层面，智能家居产品的操作方式、交互逻辑等应保持统一；最后，在信息架构和用户界面方面，智能家居产品也应遵循一致性原则。这样的设计不仅有助于提升产品的易用性和友好性，还能增强用户的整体满意度和忠诚度。

（四）交互性原则

智能家居产品在设计过程中应充分考虑用户与产品之间的互动体验。智能家居产品能依据用户当前的环境与情境提供相应的互动服务。现今智能家居产品的交互方式主要是通

（二）智能家居产品概念

智能家居概念在Wikipedia（维基百科）上有这样的解释：Home automation 或者 domotics，指家庭自动化，也就是将智能家居和智能家电、智能系统巧妙地融合了多种传感器。这些传感器能敏锐地捕捉家庭环境中的温度等信号变化，这一系统致力于提供高度个性化的服务，旨在更加精准、高效地满足用户的日常生活需求，从而大幅减轻用户的体力负担，让家庭生活变得更加便捷与舒适。

二、物联网技术下智能家居产品特点

（一）敏锐的感知力

智能产品的敏锐感知力是其核心功能之一，它使产品能超越传统设备的限制，以更高的精度和效率与周围环境进行交互。这种感知力主要依赖于先进的传感器技术、数据处理算法以及人工智能（AI）的应用。智能家居产品通过内置的各类传感器，能实时、准确地感知家庭环境中的各项数据，自动调整家居环境。小米智能音箱如图1所示，小米智能音箱可以通过分析用户的语音语调或播放的音乐类型，尝试识别用户的情绪状态，推荐更适合当前情绪的音乐。



图1 小米智能音箱

（五）个性化原则

智能家居产品在设计时应充分考虑并尊重用户的个人需求。通过智能的学习以及高度定制化的功能，为用户打造专属的智能生活空间。为了实现个性化，智能家居产品必须具备可定制性，允许用户根据自己的生活习惯、对产品的设置、界面风格等进行个性化调整。此外，个性化原则还体现在产品的智能化设计上。通过设计富有情感化的交互方式，增强产品的温度与温度，以及符合用户审美偏好的外观设计，智能家居产品能与用户建立更深层次的情感联系，提升用户的归属感和满意度。

五、结束语

物联网的兴起重新定义了人与物之间的交互模式，开启了新的内网纪元。同时也为产品设计领域探索了创新路径与灵感源泉。通过对物联网技术的探究，智能家居产品不仅实现了设备间的互联互通与智能交互，还极大地提升了用户的体验性。物联网技术的应用还能提升智能家居的智能化，使之融入用户日常生活的方方面面。未来，智能家居产品将呈现出更加多元化、个性化的发展趋势。

参考文献

- [1] 陈旭. 基于物联网的智能产品设计策略[J]. 电子技术, 2022, 51(5): 252-253.
- [2] 阮大星. 基于物联网技术下的智能家居设计研究[D]. 深圳: 深圳大学, 2019.
- [3] 李国清. 基于物联网技术的智能家居产品设计思维与案例研究[D]. 广州: 华南理工大学, 2020.

单位: 东北电力大学艺术学院

基金项目: 吉林省教育科学规划项目“基于物联网技术的智能家居产品设计思维与案例研究”（JJKY202315）

上海服饰·2024年7月 |

上海服饰·2024年7月

中国知网 <https://www.cnki.net>

中国知网 <https://www.cnki.net>

(二) 国家实用新型专利

国家实用新型专利

《一种摄影服务用摄影样品显示装置》

(授权, 第三发明人)



国家实用新型专利

《一种自动修草护理装置及充电基站》

(授权, 第三发明人)



国家实用新型专利

《一种用于风力发电机叶片覆冰监测装置》(授权)



国家实用新型专利

《一种应用于逆风抗干扰的广角阵列喷嘴》(授权)



国家实用新型专利

《一种风电塔筒爬行检修装置》(授权)



国家实用新型专利

《一种风电塔筒爬行机械》(授权)



三、实习实践

(一) 实习工作证明

字节跳动-剪映-AI 算法成片策略实习

阶跃星辰-商业化-AI 产品实习

实习证明

实习证明 - Internship Certificate

兹证明詹雨萌，有效证件号码：32010520020521022X，在本公司剪映CapCut部门实习，在职期间为2025-10-10至2026-02-05。
This document certifies that Yumeng Zhan, valid ID No. 32010520020521022X has worked as an intern in the CapCut and Jianying Department of our company from 2025-10-10 to 2026-02-05.

特别提示：实习生在离职后应继续履行对我司的保密义务，不得向第三方泄露我司及/或关联公司的任何保密信息。
This is a reminder that after leaving the Company, the intern shall continue to fulfill the obligation of confidentiality to our company and shall not disclose any confidential information of our company and/or its affiliated companies to any third party.




兹证明詹雨萌同学（身份证号：32010520020521022X）于
2025/06/16 至 2025/08/02在我公司API 及生态组实习，期间无不
良表现。

特此证明。



腾讯-市场与公关部-推荐信

阿里巴巴-国际数字商业集团-AI 业务运营实习



Alibaba International Digital Commerce Group
阿里国际数字商业集团

实习证明

兹有姓名詹雨萌，性别：女，身份证号码：32010520020521022X。自
2024-03-28起在阿里巴巴集团或其关联公司阿里集团-国际数字商业集团-AI
Business-AI 业务运营实习。实习结束时间以实际情况为准。

特此证明！



小红书

实习证明

兹证明 詹雨萌 女士/先生, 身份证号码: 32010520020521022X, 自 2024-01-29 至 2024-03-04 在 客户效能与项目组 部门 实习。

特此证明。

如有疑问, 请联系我司人事部门 021-23218502/010-86409454。



www.xiaohongshu.com

社会实践活动证明

东北电力大学:

兹有东北电力大学艺术学院编导专业2022班詹雨萌同学于2021年1月12日至2021年1月19日在国家能源集团国电环境保护研究院实习。该同学的工作是风电场中风力机群尾流干扰机理项目实验, 该学生在实习期间工作认真表现良好, 脚踏实地, 虚心请教并且努力掌握工作技能, 善于思考, 能够举一反三。能够在学校所学的知识灵活应用到具体的工作中去, 保质保量完成工作任务。同时, 该学生严格遵守我单位的各项规章制度, 社会实践时间, 服从安排, 完成任务, 尊敬实习单位人员, 与其一同合作的员工都对该学生的表现予以肯定。

特此证明。



(二) 项目实践证明

中国管理科学研究院咨询部工程技术课题管理委员会课题实践

中国管理科学研究院咨询部 工程技术课题管理委员会

课题立项通知

詹雨萌 同志:

经中国管理科学研究院咨询部工程技术课题管理委员会评审专家研究, 您申报的课题已通过审核, 同意立项, 现将相关事宜通知如下:

课题名称: 平面设计视觉传达效果和中国传统美术色彩分析研究

课题类别: 重点课题

课题批准号: ZGYGC17742

课题研究时间: 2022年2月-2023年2月

根据工程技术课题管理委员会的有关课题管理规定, 请您及课题组其他成员做好下列工作:

- 1、尽快确定具体的实施方案、组织开题, 并将课题实施方案和课题情况报送上级主管部门备案。
- 2、严格执行《工程技术课题管理委员会课题管理办法》, 根据课题成果预期做好课题的调研及自我管理实施工作。课题重要活动、重要变更和重要成果均须经单位科研管理部门签署一并报上级主管部门。
- 3、研究期间应按申报表设定的时间和内容认真进行。结题时需对课题研究过程和获得的成果进行总结并写出结题报告(或实验报告)。



中国管理科学研究院咨询部 工程技术课题管理委员会

课题结题通知

詹雨萌 同志:

您申报的课题《平面设计视觉传达效果和中国传统美术色彩分析研究》(项目编号: ZGYGC17742), 根据工程技术课题管理委员会的有关课题管理规定, 经中国管理科学研究院咨询部工程技术课题管理委员会评审专家对提交的课题报告材料和相关成果附件, 从科学性、规范性、创新性和应用价值等方面逐一进行赋分鉴定, 课题研究成果达到了预期的研究目标, 同意结题, 并颁发结题证书。

特此通知!




上海广播电视台 SMG 故宫百年专题《AIGC 穿越
600 年：从紫禁城到故宫博物院》AIGC 特约编辑



《上海交通大学建校 130 周年公告》
AI 编剧、制作



“戏韵中华·友谊长青”上海市区校联动民间外交
“海派绮梦·戏墨丹青”海派戏曲展主策展人



哔哩哔哩 2025 年毕业歌《我们都很棒》
制片助理



Step-Audio 2 Technical Report

StepFun Audio Team

Abstract

This paper presents Step-Audio 2, an end-to-end multi-modal large language model designed for industry-strength audio understanding and speech conversation. By integrating a latent audio encoder and reasoning-centric reinforcement learning (RL), Step-Audio 2 achieves promising performance in automatic speech recognition (ASR) and audio understanding. To facilitate genuine end-to-end speech conversation, Step-Audio 2 incorporates the generation of discrete audio tokens into language modeling, significantly enhancing its responsiveness to paralinguistic information such as speaking styles and emotions. To effectively leverage the rich textual and acoustic knowledge in real-world data, Step-Audio 2 integrates retrieval-augmented generation (RAG) and is able to call external tools such as web search to mitigate hallucination and audio search to switch timbres. Trained on millions of hours of speech and audio data, Step-Audio 2 delivers intelligence and expressiveness across diverse conversational scenarios. Evaluation results demonstrate that Step-Audio 2 achieves state-of-the-art performance on various audio understanding and conversational benchmarks compared to other open-source and commercial solutions. Please visit <https://github.com/stepfun-ai/Step-Audio2> for more information.

1 Introduction

With the rapid development of large language models and audio processing technology, large audio language models (LALMs) have demonstrated their superiority over conventional approaches in various speech and audio processing tasks. GPT-4o is first introduced and is pioneering the development of end-to-end speech interaction without intermediate textual conversions. Subsequently, many open-sourced LALMs [9, 13, 16, 18, 21, 31, 32, 49, 71, 72, 74, 77] are emerged, advancing multi-modal large language model capabilities in various speech and audio domains. Among these approaches, Qwen-Audio [12] and Qwen2-Audio [13] perform audio analysis and generate textual responses to speech instructions. Qwen2.5-Omni [74] implements a thinker-talker architecture to enable full-duplex I/O during speech conversations. More recently, Kimi-Audio [18] has achieved impressive results on multiple speech and audio understanding benchmarks. In parallel, we have introduced Step-Audio [32] and Step-Audio-AQAA [31], the first LALMs to unify speech understanding and generation through discrete audio tokens at a scale of 130 billion parameters.

However, existing LALMs still face challenges in achieving natural and intelligent speech interaction. Previous LALMs such as Spirit LM [49] and GLM-4-Voice [77] mainly focus on aligning the semantic information in speech inputs to text modal, neglecting the para-linguistic information which is also crucial for intentional understanding. Although LALMs including Qwen-Audio [12], Qwen2-Audio [13] and Audio Flamingo series [24, 25, 43] are capable of comprehending such information, they typically generate only textual outputs and fail to further utilize this capability




Figure 1: Performance comparison of GPT-4o Audio¹, Kimi-Audio², Qwen-Omni³ and Step-Audio 2 and on various benchmarks.

to produce coherent and expressive responses in speech conversations. Moreover, due to the complexities of multi-modal modeling, existing LALMs frequently suffer from hallucination and offer limited choices of timbres and speaking styles [16, 18], lacking access to real-world textual and acoustic knowledge.

To address these issues and step into the next generation of multi-modal large language models, we present **Step-Audio 2**, an end-to-end large audio language model with industry-strength audio perception and speech interaction. Step-Audio 2 directly processes raw audio as input and outputs discrete text and audio tokens and has fewer parameters than Step-Audio [32]. Beyond capturing semantic information in speech, the model also comprehends para-linguistic and non-vocal information in audio. By leveraging chain-of-thought (CoT) reasoning and reinforcement learning (RL), Step-Audio 2 further utilizes such multi-modal information to generate expressive speech responses coherent to different conversation scenarios. To ground the model with real-world knowledge, Step-Audio 2 incorporates retrieval-augmented generation (RAG) and the capability to utilize various external tools, including web search and audio search, to provide more reliable and expressive responses. Specifically, we present an audio search as a tool unique to LALMs, enabling seamless speech retrieval via voice instructions and allowing the model to switch timbres and speaking styles based on the retrieved speech.

¹GPT-4o Audio is evaluated with gpt-4o-transcribe for ASR and gpt-4o-audio-preview-2025-06-03 for others via official API.

²Kimi-Audio is excluded from translation evaluations since it consistently ignores prompts.

³Qwen-Omni is evaluated with Qwen2.5-Omni for MMAU and speech-to-text translation, and qwen-omni-turbo-2025-03-26 for others via official API.




Figure 2: Illustration of the applications of Step-Audio 2 across various speech conversation scenarios.

To ensure its intelligence and expressiveness in diverse conversational scenarios, we carefully design a multi-stage training strategy to train Step-Audio 2 on 680 billion tokens of text data and 8 million hours of real and synthesized audio data. Evaluation results shown in Figure 1 demonstrate that Step-Audio 2 achieves state-of-the-art performance in a series of audio tasks, including automatic speech recognition (ASR) on multiple languages, audio understanding, speech-to-speech translation and speech-to-speech conversation. Typical usages of Step-Audio 2 are also illustrated in Figure 2.

2 Related Work

2.1 Speech and audio understanding

Recent advances in large language models (LLMs) [4, 29, 50, 51] have extended their application to a wide range of speech and audio understanding tasks, such as audio captioning, sound event detection, automatic speech recognition, audio classification, and audio-driven creative generation. A prevalent approach [13, 17, 27, 28, 48, 61] involves pairing speech encoders with lightweight, trainable adapters that project audio features into a textual embedding space compatible with LLMs. Building on this foundation, recent studies have further explored how to incorporate paralinguistic information such as emotion, intonation and speaker style, enabling LLMs to move beyond pure linguistic comprehension. For instance, ParalinGPT [48] focuses on enhancing a powerful text-based language model by integrating continuous speech embeddings, enabling it to capture paralinguistic signals such as emotion and prosody. SALMONN [61] adopts a multi-modal strategy by freezing speech encoders Whisper [53] and BEATs [10], and connecting their outputs to an LLM via a window-level Q-Former, enabling joint modeling of linguistic and acoustic features. Seed-ASR [5] integrates LUISE-based speech representations with instructions and context, using context-aware SFT to capture semantic information. AudioPaLM [57] combines PaLM-2 [2] and AudioLM [7], unifying linguistic knowledge with paralinguistic features like speaker identity and intonation. LLM-based approaches [12, 13] increasingly rely on pretrained audio encoders such as Wav2Vec [3], HuBERT [30], Whisper [53], and WavLM [11] to extract rich semantic representations from speech. At the same time, the extensive text knowledge and contextual reasoning capabilities stored in LLMs can provide valuable semantic guidance for understanding tasks.

2.2 Text-to-speech synthesis

Text-to-Speech (TTS) technology has made remarkable strides in recent years, evolving from traditional concatenative and statistical parametric approaches [52, 55, 59, 68] to codec-based TTS systems. Codec language models leverage a speech codec to extract discrete representations of speech [15, 16, 36, 60, 73, 76, 81, 82] and utilize either autoregressive [18, 80] or masked language models [67] to predict the corresponding speech tokens. These tokens are then synthesized into waveforms using codec vocoders. VALL-E [64] marked a significant breakthrough in this area. It uses an autoregressive model to generate coarse codec codes, followed by a non-autoregressive model for the fine codes. Unlike VALL-E, which predicts acoustic tokens from phonemes and requires transcripts, SPEAR-TTS [40] uses a two-stage architecture with self-supervised audio prompts to clone unseen voices from just 3 seconds of speech. SparkTTS [65] introduces BiCodec, a single-stream speech codec that encodes linguistic content as compact semantic tokens and speaker characteristics as fixed-length global tokens. Instead of relying on non-autoregressive models to predict residual discrete codes, methods like TorToiseTTS [6], CosyVoice [20], CosyVoice 2 [19], MiniMax-Speech [79] and SEED-TTS [1] adopt diffusion or flow-matching techniques as a second stage to reconstruct mel-spectrograms or continuous representations enriched with fine-grained acoustic and semantic details. Recent work, Kimi-Audio [18] combines Whisper features and semantic tokens for efficient modeling, with dual heads and a flow-matching detokenizer plus BigVGAN [46] for low-latency, expressive synthesis.

2.3 Speech-to-speech translation

Speech-to-speech translation (S2ST) is a crucial technology for eliminating communication barriers across languages. Traditional S2ST systems [62, 70] typically adopt a cascaded pipeline consisting of automatic speech recognition (ASR), machine translation (MT), and TTS modules. Earlier studies [38, 39, 44, 45] have shifted toward direct approaches that bypass intermediate textual representations, aiming for lower latency and better preservation of prosody and speaker characteristics. Two main types of direct S2ST methods have emerged, which are known as speech-to-spectrogram translation and speech-to-unit translation. Both directly generate target speech representations from the source speech without relying on textual transcriptions. A representative of the former is Translatotron [38], the first end-to-end model to translate source speech directly into target spectrograms. Translatotron 2 [39], further improves translation quality through a two-pass decoding mechanism [45]. In contrast, speech-to-unit models predict discrete acoustic tokens rather than spectrograms, which are typically extracted using self-supervised speech encoders such as HuBERT [30] or WavLM [11]. For instance, TransVIP [44] employs a joint encoder-decoder architecture that first generates target text and residual vector quantization (RVQ) codes in the initial layer, followed by a non-causal language model that refines RVQ predictions in subsequent layers.

2.4 Speech-to-text and speech-to-speech conversation

Based on whether the LLM can directly understand and generate speech representations, existing systems can be categorized into end-to-end large audio language models and cascaded large audio language models. The former directly models audio inputs and outputs within a unified framework, while the latter relies on a modular pipeline involving separate ASR, LLM, and TTS components. Traditional speech-to-text and speech-to-speech systems typically adopt a cascaded architecture, as exemplified by AudioGPT [33] and Spoken-LLM [47]. However, the ASR + LLM + TTS pipeline incurs high latency and modular mismatches. This has spurred interest in unified end-to-end architectures for faster and more seamless integration. A major milestone in this direction is GPT-4o [34], which supports direct end-to-end speech interaction without requiring intermediate textual conversions. Recently, several new end-to-end LALMs [16, 21, 71, 72, 74] for speech-to-speech conversation have emerged. For instance, Moshi [16] improves efficiency with an RQ-Transformer that generates text and audio tokens simultaneously. Similarly, Mini-Omni [71] generates speech and text responses in parallel, following a strategy similar to MusicGen [14], which enables lower first-token latency compared to interleaved generation designs. LUCY [22] builds on the Mini-Omni architecture with enhancements for emotional expressiveness, naturalness, and informativeness in speech generation. It utilizes curated synthetic data and optimizes the training and decoding pipelines to handle multi-turn dialogue and function-call scenarios. Mini-Omni2 [71] further extends Mini-Omni framework by integrating multimodal understanding and full-duplex interaction capabilities. LLaMA-Omni [21] introduces a streaming, non-autoregressive speech decoder based on Connectionist Temporal Classification, enabling direct and efficient generation of discrete audio tokens without relying on step-by-step prediction. Freeze-Omni [66], on the other hand, freezes the LLM parameters during training, preserving its original capabilities while achieving low-latency speech-to-speech interaction through streaming and decoder integration. Qwen2.5-Omni [74] supports multimodal input and simultaneous text-speech output via a thinker-talker architecture, using TMRoPE for improved audio-visual synchronization through explicit temporal encoding.




Figure 3: Architecture of the Step-Audio 2.

3 Methodology

3.1 Architecture

Different from our previous Step-Audio [32], Step-Audio 2 further integrates the generation of audio tokens into language modeling, achieves end-to-end audio perception and generation. As shown in Figure 3, Step-Audio 2 consists of an audio encoder, an audio adaptor, an LLM decoder and an audio detokenizer.

The audio encoder is pretrained on various speech and audio understanding tasks including ASR, speaker age and gender prediction, audio event detection, etc. The audio encoder has an output frame rate of 25 Hz and is frozen during the entire training process. An audio adaptor with a downsampling rate of 2 is employed to connect the audio encoder to LLM, thereby reducing the output frame rate of the audio encoder to 12.5 Hz.

The LLM decoder directly takes the latent audio features from the audio adaptor as input, and outputs an interleaved sequence of discrete text and audio tokens. We employ the tokenizer from CosyVoice 2 [19] as the audio tokenizer. And the text and audio tokens are interleaved [31, 32, 77] at a fixed ratio and padded at the end to meet the ratio. The audio tokens are then extracted from the interleaved sequence and consumed by the audio detokenizer to generate the output waveform. The input audio features and output interleaved sequences are then pre-filled as the history information for the next round of conversation.

To provide more accurate responses and expand interactive capabilities, we design tools to retrieve audio, current date and time, weather forecast and web content directly with explicit or implicit voice inputs. Notably, we propose the audio search tool, a novel tool with a voice library of hundreds of thousands of speeches with their corresponding transcriptions and descriptions. With the retrieved speech from audio search, Step-Audio 2 is able to mimic the speaking style or switching timbre

according to the speech. During inference, the retrieved information is appended after the input audio features before generating speech outputs.

Similar to Step-Audio [32] and Step-Audio-AQAA [31], Step-Audio 2’s audio detokenizer also consists of a Flow Matching module and a HiFi-GAN [42] vocoder. The Flow-Matching module generates Mel spectrograms from the output audio tokens, while the vocoder further converts the Mel spectrograms into waveforms. For Flow-Matching, we incorporate a CNN-based encoder layer after each self-attention module within the transformer block and train the model on 200,000 hours of high-quality speech. This enhancement significantly improves its Mel spectrogram reconstruction capability, leading to substantial gains in both pronunciation accuracy and timbre similarity.

Step-Audio 2 employs the same deployment infrastructure used in Step-Audio [32] and Step-Audio-AQAA [31], which includes a voice activity detection (VAD) module to filter out input speeches and achieves real-time voice conversation.

3.2 Pre-training

Step-Audio 2 model is initialized with a textual LLM and then continually pre-trained on 1.356T tokens of textual and audio data over 21 days.

We first utilize 100B tokens of ASR data to facilitate effective alignment between speech and text feature spaces within the adaptor. During this phase, both the audio encoder and LLM are frozen, with only the adaptor being trained. We conduct training for 12K steps at an 8,192 sequence length. And the learning rate decays from 10^{-4} to 2×10^{-5} .

We then extend the tokenizer of the textual LLM with 6.6K audio tokens. To properly embed the new audio tokens and preserve the model’s textual capabilities, the model is then trained on 128B tokens of text data and 128B tokens of audio data. Specifically, audio data includes 80B, 32B and 16B tokens of TTS, speech-to-speech conversation and utterance-level text-speech interleaved continuation data respectively. The sequence length is increased to 16,384. And the learning rates of the LLM, adaptor, embedding layer and output layer are set to 2×10^{-5} , 5×10^{-5} , 5×10^{-5} , and 4×10^{-5} respectively.

We then introduce our main pre-training process and further train the model on another 800B tokens of text and audio data. We unify the learning rates to 2×10^{-5} and employ 400B tokens of textual data and 42B, 120B, 8B, 30B, 5B, 45B and 150B tokens of ASR, TTS, speech-to-text translation, text-to-speech translation, speech-to-text continuation, utterance-level text-speech interleaved continuation and speech-to-speech conversation data respectively.

We finally employ 200B tokens of high-quality text and audio data to introduce a wider array of tasks and cooldown the model. We employ 24.6B, 12.4B, 2.4B, and 3.6B tokens of audio data for multilingual and dialectal ASR, TTS, paralinguistic information understanding, speech-to-text translation respectively. Besides, we develop a conversational speech synthesis pipeline to synthesize 6B, 15B and 36B tokens of audio data for speech-to-speech translation, utterance-level text-speech interleaved conversation and speech-to-speech conversation. To ensure the vocal diversity in the synthesized speech, the system references a library of approximately 50k unique speakers. We balance the audio data with 100B tokens of high-quality text data and the learning rate decays from 2×10^{-5} to 5×10^{-6} .

After this comprehensive pre-training procedure, the model has acquired strong audio understanding and generation capabilities while maintaining its textual performance inherited from the initial textual LLM.

3.3 Supervised fine-tuning

We subsequently perform a large-scale, multi-task supervised fine-tuning (SFT) procedure [69] to instruct the model to follow human intention in fluid conversations and master core tasks. We select audio data from open-source and proprietary data to ensure broad coverage and high quality. The model is trained on 4B tokens of text and audio data for a single epoch. And the learning rate decays from 10^{-5} to 10^{-6} .

Specifically, we leverage extensive corpora such as GigaSpeech [8], WenetSpeech [78], and other in-house data to enhance the model’s performance in multilingual and multi-dialect ASR scenarios. We reformat existing datasets for audio event classification and audio captioning, such as AudioSet [23] and AudioCaps [41], into speech question-answer pairs for audio understanding. To capture paralinguistic information beyond just semantics, we introduce a detailed speech captioning task and build an in-house dataset, requiring the model to generate comprehensive textual descriptions encompassing 11 paralinguistic and environmental aspects.

We employ high-quality, professionally labeled data collected in-house for TTS. We utilize the Chinese-to-English and English-to-Chinese subsets from the CoVoST 2 [63] dataset for speech-to-speech translation.

We leverage high-quality in-house textual data for classic text-to-text conversation. Multiple LLMs are then employed to rewrite these text conversations as dialogue scripts with a more natural, colloquial style. We randomly insert emotion and speed instructions into the generated scripts to enable basic emotion and speaking style control. The scripts are then synthesized into speech conversations using our conversation synthesis pipeline.

We construct approximately 1K dialogue scripts in text for each type of external tools. Within these scripts, instructions with explicit or implicit tool invocation intentions and their corresponding statements are inserted into common dialogues. The scripts are then synthesized into speech conversations using our conversation synthesis pipeline.

Besides, we construct and employ two reasoning-centric datasets during SFT to cold-start the subsequent reinforcement learning process. First, we build a dataset to enable and robust audio understanding in complex acoustic scenarios, by combining multiple audios from AudioSet and AudioCaps, thereby creating intricate acoustic environments. To better address and respond to the paralinguistic information in speech conversations, we synthesize a speech conversation dataset with our conversation synthesis pipeline, based on dialogue scripts with appropriate emotion descriptions generated from textual LLMs. Subsequently, a textual LLM with reasoning capabilities is employed to produce question-answer pairs with explicit step-by-step reasoning traces, according to the audio mixing recipes or the generated dialogue scripts.

3.4 Reinforcement learning

To enhance the model’s reasoning capabilities in audio understanding and speech interaction, we implement a multi-stage reinforcement learning strategy. We leverage our reasoning-centric datasets from SFT and utilize two stages of proximal policy optimization (PPO) [54] to optimize reasoning

efficiency for real-time audio engagement. In the first stage, a binary reward function is employed to limit the thinking sequence length to a predefined maximum. This reward function assigns a value of 1 for reasoning that is appropriately concise (neither empty nor excessively long) and 0 otherwise. Training is conducted for 60 iterations with a global batch size of 64, using an actor learning rate of 1×10^{-6} and a critic learning rate of 2.5×10^{-6} . The second stage transitions from binary rewards to learned preference scoring, utilizing a trained reward model to evaluate response quality. This stage involves an additional 120 iterations while maintaining the same batch size and learning rate settings. Finally, we incorporate group relative policy optimization (GRPO) [54] for 400 iterations to further improve the model’s audio perceptual abilities.

4 Evaluation

4.1 Automatic speech recognition

As the most critical component of audio understanding and speech interaction, we first evaluate the model’s capability in automatic speech recognition. We evaluate Step-Audio 2 across six Chinese test sets, four English test sets, three multilingual test sets (Japanese, Cantonese, Arabic), and six in-house Chinese dialect and accented Mandarin test sets. For comparative analysis, we utilize top-performing models from both open-source and commercial domains as baselines, including Doubao LLM ASR¹, GPT-4o Transcribe², Kimi-Audio [18], and Qwen-Omni. We prefer GPT-4o Transcribe than GPT-4o Audio since the formers provide stronger results. Notably, Doubao LLM ASR and GPT-4o Transcribe represent specialized ASR systems that achieve leading-edge performance.

We evaluate all the models without specifying language³ and summarize the results in Table 1. Step-Audio 2 outperforms existing open-source and commercial ASR models in both general English and Chinese recognition, achieving an average word error rate (WER) of 3.14% on English and an average character error rate (CER) of 3.08% on Chinese test sets. Moreover, Step-Audio 2 offers comparable results to GPT-4o Transcribe on Arabian and Japanese recognition, to Qwen-Omni on Cantonese recognition, demonstrating its capability in multilingual speech recognition. In addition, Step-Audio 2 achieves the lowest average CER among 4 in-house Chinese accented Mandarin and 2 dialect test sets. These results highlight the superiority of Step-Audio 2 in understanding the semantic information in speech.

4.2 Paralinguistic information understanding

We then evaluate how Step-Audio 2 understands the paralinguistic information in speech beyond the semantic information. To this end, we introduce StepEval-Audio-Paralinguistic, a speech-to-speech benchmark that evaluates the model’s understanding of paralinguistic information across 11 dimensions using single-turn question answering.

StepEval-Audio-Paralinguistic comprises 550 speech samples evenly distributed across 11 tasks. We initially collect 400 Chinese speech clips for 8 of these tasks from public podcast recordings, encompassing gender, age, timbre, emotion, pitch, rhythm, speaking speed, speaking style, and vocal activity prediction or description. For sound event, scenario, and vocal sound detection or

¹Doubao LLM ASR refers to <https://www.volcengine.com/docs/6561/1354868>

²GPT-4o Transcribe is evaluated using its latest model, gpt-4o-transcribe, via its official API.

³We evaluate without specifying language to ensure a fair comparison. Notably, Qwen-Omni lacks a language-independent testing approach, specifying language may yield better results.

Table 1: Comparison between Doubao LLM ASR, GPT-4o Transcribe, Kimi-Audio, Qwen-Omni and Step-Audio 2, on character (for Chinese, Cantonese and Japanese) and word (for Arabian and English) error rates among multiple ASR test sets. N/A indicates that the language is not supported.

Category	Test set	Doubao LLM ASR	GPT-4o Transcribe	Kimi-Audio	Qwen-Omni	Step-Audio 2
English	Common Voice	9.20	9.30	7.83	8.33	5.95
	FLEURS English	7.22	2.71	4.47	5.05	3.03
	LibriSpeech clean	2.92	1.75	1.49	2.93	1.17
	LibriSpeech other	5.32	4.23	2.91	5.07	2.42
	Average	6.17	4.50	4.18	5.35	3.14
Chinese	AISHELL	0.98	3.52	0.64	1.17	0.63
	AISHELL-2	3.10	4.26	2.67	2.40	2.10
	FLEURS Chinese	2.92	2.62	2.91	7.01	2.68
	KeSpeech phase1	6.48	26.80	5.11	6.45	3.63
	WenetSpeech meeting	4.90	31.40	5.21	6.61	4.75
	WenetSpeech net	4.46	15.71	5.93	5.24	4.67
	Average	3.81	14.05	3.75	4.81	3.08
Multilingual	FLEURS Arabian	N/A	11.72	N/A	25.13	14.22
	Common Voice yue	9.20	11.10	38.90	7.89	7.90
	FLEURS Japanese	N/A	3.27	N/A	10.49	3.18
In-house	Anhui accent	8.83	50.55	22.17	18.73	10.61
	Guangdong accent	4.99	7.83	3.76	4.03	3.81
	Guangxi accent	3.37	7.09	4.29	3.35	4.11
	Shanxi accent	20.26	55.03	34.71	25.95	12.44
	Sichuan dialect	3.01	32.85	5.26	5.61	4.35
	Shanghai dialect	47.49	89.58	82.90	58.74	17.77
	Average	14.66	40.49	25.52	19.40	8.85

description, we source 50 event-related, 50 environmental, and 50 vocal sounds from AudioSet [23], CochlScene [35], and VocalSound [26], respectively. All original recordings are shorter than 30 seconds and uniformly resampled to 24,000 Hz, with annotations provided by professional groups in open-set natural language.

We then generate textual questions and answers based on the ground-truth annotations for each task with textual LLMs. For the first 8 tasks, we use the input speech as a prompt to clone a synthesized question speech and randomly concatenate the question before or after the original speech. For the remaining 3 tasks, we further mix these audios with synthesized speeches before question concatenation, creating more challenging test samples.

We also establish an automatic evaluation protocol for StepEval-Audio-Paralinguistic, which initially transcribes model outputs into text using ASR, followed by automatic judgment with a textual LLM. More information, along with the complete StepEval-Audio-Paralinguistic test set and evaluation code, is available at <https://github.com/stepfun-ai/Step-Audio2> to foster further research on paralinguistic information understanding.

We evaluate GPT-4o Audio, Kimi-Audio, Qwen-Omni, Step-Audio-AQAA, and Step-Audio 2 using the StepEval-Audio-Paralinguistic benchmark, with results presented in Table 2. The experimental results highlight the comprehensive capabilities of Step-Audio 2 in understanding various paralinguistic information, achieving an average accuracy of 83.09, which is a significant improvement over other baseline models.

Table 2: Comparison between GPT-4o Audio, Kimi-Audio, Qwen-Omni, Step-Audio-AQAA and Step-Audio 2 on StepEval-Audio-Paralinguistic.

Model	Avg.	Gender	Age	Timbre	Scenario	Event
GPT-4o Audio	43.45	18	42	34	22	14
Kimi-Audio	49.64	94	50	10	30	48
Qwen-Omni	44.18	40	50	16	28	42
Step-Audio-AQAA	36.91	70	66	18	14	14
Step-Audio 2	83.09	100	96	82	78	60

Model	Emotion	Pitch	Rhythm	Speed	Style	Vocal
GPT-4o Audio	82	40	60	58	64	44
Kimi-Audio	66	56	40	44	54	54
Qwen-Omni	76	32	54	50	50	48
Step-Audio-AQAA	40	38	48	54	44	0
Step-Audio 2	86	82	86	88	88	68

4.3 Audio understanding

We then assess Step-Audio 2’s general audio comprehension across sound, speech, and music using the latest version of the MMAU benchmark [58]¹.

As baselines, we employ Audio Flamingo 3, Gemini 2.5 Pro, GPT-4o Audio, Kimi-Audio, Omni-R1 [56], Qwen2.5-Omni, and Step-Audio-AQAA. We obtain the reported results for Audio Flamingo 3, Omni-R1, and Qwen2.5-Omni from their original papers. The results of Gemini 2.5 Pro are obtained from the official website of MMAU. And we re-evaluate GPT-4o Audio, Kimi-Audio and Step-Audio-AQAA due to the recent update of the MMAU benchmark.

The results are summarized in Table 3. Step-Audio 2 achieves the highest average score of 78.0, followed by Omni-R1 and Audio Flamingo 3, both of which are specialized approaches in audio understanding. Specifically, Step-Audio 2 yields the best results in sound and speech tracks and on par results with the best in music track, demonstrating its versatility and robustness across different audio domains.

Table 3: Comparison between Audio Flamingo 3, Gemini 2.5 Pro, GPT-4o Audio, Kimi-Audio, Omni-R1, Qwen2.5-Omni, Step-Audio-AQAA and Step-Audio 2 on MMAU.

Model	Avg.	Sound	Speech	Music
Audio Flamingo 3	73.1	76.9	66.1	73.9
Gemini 2.5 Pro	71.6	75.1	71.5	68.3
GPT-4o Audio	58.1	58.0	64.6	51.8
Kimi-Audio	69.6	79.0	65.5	64.4
Omni-R1	77.0	81.7	76.0	73.4
Qwen2.5-Omni	71.5	78.1	70.6	65.9
Step-Audio-AQAA	49.7	50.5	51.4	47.3
Step-Audio 2	78.0	83.5	76.9	73.7

4.4 Speech translation

We evaluate the model’s bidirectional Chinese-English speech translation capabilities using two benchmarks: speech-to-text translation (S2TT) on CoVoST 2 [63] and speech-to-speech translation

¹MMAU v05.15.25 test-mini

(S2ST) on CVSS [37]. Additionally, we use the reported results of Qwen2.5-Omni for CoVoST 2, while for CVSS, we employ Qwen-Omni as a baseline. Kimi-Audio is excluded because it consistently ignores prompts and performs ASR instead of translation. Using BLEU as the evaluation metric, the results in Table 4 demonstrate that Step-Audio 2 achieves superior performance in Chinese-English bidirectional translations, obtaining the highest average score on both the CoVoST 2 and CVSS test sets.

Table 4: Comparison of BLEU scores between GPT-4o Audio, Qwen2.5-Omni, Qwen-Omni, Step-Audio-AQAA and Step-Audio 2 on speech-to-text and speech-to-speech translation.

Model	CoVoST 2 (Speech-to-text translation)		
	Avg.	English-to-Chinese	Chinese-to-English
GPT-4o Audio	29.61	40.20	19.01
Qwen2.5-Omni	35.40	41.40	29.40
Step-Audio-AQAA	28.57	37.71	19.43
Step-Audio 2	39.26	49.01	29.51

Model	CVSS (Speech-to-speech translation)		
	Avg.	English-to-Chinese	Chinese-to-English
GPT-4o Audio	23.68	20.07	27.29
Qwen-Omni	15.35	8.04	22.66
Step-Audio-AQAA	27.36	30.74	23.98
Step-Audio 2	30.87	34.83	26.92

4.5 Tool calling

To address the gap in the availability of suitable test sets for tool calling in speech conversations, we introduce StepEval-Audio-Toolcall, a test set that evaluates the model’s ability in tool invocation, selection and parameter extraction under Chinese speech conversations.

We employ a textual LLM to generate 200 multi-turn dialogue scripts for each kind of tool. Each script contains 3-6 turns of inputs and outputs, in which previous turns may or may not include tool calling statements, but the final input must contain a calling intention to a specific external tool. We then balance the samples with an equal number of negative samples for each kind of tools, in which the final speech input either has no tool calling intention or intention to call on other kinds of tools. Subsequently, we synthesize these scripts into speeches with our conversation synthesis pipeline. And we propose an automatic evaluation protocol to employ Qwen3-32B to automatically examine the output and tool calling statements. We release StepEval-Audio-Toolcall including the original scripts, synthesized speech conversations and the corresponding evaluation script in <https://github.com/stepfun-ai/Step-Audio2>.

Despite that there is no other LALM that provides custom tool calling, we employ Qwen3-32B as a baseline to illustrate how Step-Audio 2 manages external tools in comparison to textual LLMs. As shown in Table 5, Step-Audio 2 achieves on par with tool calling accuracy with textual LLMs even with speech input. Notably, Step-Audio 2 significantly outperforms Qwen3-32B in accurately calling our innovative audio search tool, highlighting its specialty as a multi-modal LLM than textual LLMs.

Table 5: Comparison between Step-Audio 2 and Qwen3-32B on StepEval-Audio-Toolcall. [†]Qwen3-32B is evaluated with text inputs. [‡]Date and time tools have no parameter.

Model	Objective	Metric	Audio search	Date & Time [‡]	Weather	Web search
Qwen3-32B [†]	Trigger	Precision / Recall	67.5 / 98.5	98.4 / 100.0	90.1 / 100.0	86.8 / 98.5
	Type	Accuracy	100.0	100.0	98.5	98.5
	Parameter	Accuracy	100.0	N/A	100.0	100.0
Step-Audio 2	Trigger	Precision / Recall	86.8 / 99.5	96.9 / 98.4	92.2 / 100.0	88.4 / 95.5
	Type	Accuracy	100.0	100.0	90.5	98.4
	Parameter	Accuracy	100.0	N/A	100.0	100.0

4.6 Speech-to-speech conversation

We finally employ URO-Bench [75] to evaluate Step-Audio 2 and other open-source and commercial LALMs, including GPT-4o Audio, Kimi-Audio, Qwen-Omni, and Step-Audio-AQAA. URO-Bench consists of multiple datasets on two difficulty tracks, evaluating the model’s understanding, reasoning and oral conversation abilities, such as ASR, instruction following, commonsense knowledge, mathematics, and speech naturalness, emotion and speaking styles expressions. We follow the ASR-mediated procedure in URO-Bench for evaluation, employing Whisper for ASR and GPT-4o-mini for automatic judging.

As demonstrated in Table 6, Step-Audio 2 significantly outperforms existing large audio language models, including GPT-4o Audio, in Chinese speech-to-speech conversation scenarios, achieving the highest average scores of 83.32 on the basic track and 68.25 on the pro track. In English speech-to-speech conversations, while Step-Audio 2 is slightly outperformed by GPT-4o Audio, it provides very competitive results and exceeds the other approaches.

Table 6: Comparison between GPT-4o Audio, Kimi-Audio, Qwen-Omni, Step-Audio-AQAA and Step-Audio 2 on the URO-Bench. U. R. O. stands for understanding, reasoning, and oral conversation, respectively.

Model	Language	Basic				Pro			
		Avg.	U.	R.	O.	Avg.	U.	R.	O.
GPT-4o Audio	Chinese	78.59	89.40	65.48	85.24	67.10	70.60	57.22	70.20
Kimi-Audio		73.59	79.34	64.66	79.75	66.07	60.44	59.29	76.21
Qwen-Omni		68.98	59.66	69.74	77.27	59.11	59.01	59.82	58.74
Step-Audio-AQAA		74.71	87.61	59.63	81.93	65.61	74.76	47.29	68.97
Step-Audio 2		83.32	91.05	75.45	86.08	68.25	74.78	63.18	65.10
GPT-4o Audio	English	84.54	90.18	75.90	90.41	67.51	60.65	64.36	78.46
Kimi-Audio		60.04	83.36	42.31	60.36	49.79	50.32	40.59	56.04
Qwen-Omni		70.58	66.29	69.62	76.16	50.99	44.51	63.88	49.41
Step-Audio-AQAA		71.11	90.15	56.12	72.06	52.01	44.25	54.54	59.81
Step-Audio 2		83.90	92.72	76.51	84.92	66.07	64.86	67.75	66.33

5 Conclusion

We introduce Step-Audio 2, an end-to-end large audio language model designed for enterprise speech and audio understanding, as well as intelligent speech interaction. Step-Audio 2 leverages a latent audio encoder and reinforcement learning to enhance its speech and audio comprehension capabilities. Furthermore, by integrating the generation of discrete audio tokens into language modeling, Step-Audio 2 achieves genuine end-to-end speech interaction and improves its responsiveness

to paralinguistic information, such as speaking styles and emotions. Step-Audio 2 is also capable of utilizing external tools including web search and audio search for multi-modal RAG. Trained on 8 million hours of speeches and audios, Step-Audio 2 demonstrates state-of-the-art performance across various tasks, including ASR, audio understanding, speech translation, and general speech conversation, outperforming both open-source and commercial solutions.

References

- [1] Philip Anastassiou et al. “Seed-tts: A family of high-quality versatile speech generation models”. In: *arXiv preprint arXiv:2406.02430* (2024).
- [2] Rohan Anil et al. *PaLM 2 Technical Report*. 2023. arXiv: 2305.10403 [cs.CL]. URL: <https://arxiv.org/abs/2305.10403>.
- [3] Alexei Baevski et al. *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*. 2020. arXiv: 2006.11477 [cs.CL]. URL: <https://arxiv.org/abs/2006.11477>.
- [4] Jinze Bai et al. *Qwen Technical Report*. 2023. arXiv: 2309.16609 [cs.CL]. URL: <https://arxiv.org/abs/2309.16609>.
- [5] Ye Bai et al. “Seed-asr: Understanding diverse speech and contexts with llm-based speech recognition”. In: *arXiv preprint arXiv:2407.04675* (2024).
- [6] James Betker. *Better speech synthesis through scaling*. 2023. arXiv: 2305.07243 [cs.SD]. URL: <https://arxiv.org/abs/2305.07243>.
- [7] Zalán Borsos et al. “Audiolm: a language modeling approach to audio generation”. In: *IEEE/ACM transactions on audio, speech, and language processing* 31 (2023), pp. 2523–2533.
- [8] Guoguo Chen et al. “GigaSpeech: An Evolving, Multi-Domain ASR Corpus with 10,000 Hours of Transcribed Audio”. In: *Interspeech 2021*. ISCA, Aug. 2021. DOI: 10.21437/interspeech.2021-1965. URL: <http://dx.doi.org/10.21437/Interspeech.2021-1965>.
- [9] Qian Chen et al. “Minmo: A multimodal large language model for seamless voice interaction”. In: *arXiv preprint arXiv:2501.06282* (2025).
- [10] Sanyuan Chen et al. *BEATs: Audio Pre-Training with Acoustic Tokenizers*. 2022. arXiv: 2212.09058 [eess.AS]. URL: <https://arxiv.org/abs/2212.09058>.
- [11] Sanyuan Chen et al. “WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing”. In: *IEEE Journal of Selected Topics in Signal Processing* 16.6 (Oct. 2022), pp. 1505–1518. ISSN: 1941-0484. DOI: 10.1109/jstsp.2022.3188113. URL: <http://dx.doi.org/10.1109/JSTSP.2022.3188113>.
- [12] Yunfei Chu et al. “Qwen-audio: Advancing universal audio understanding via unified large-scale audio-language models”. In: *arXiv preprint arXiv:2311.07919* (2023).
- [13] Yunfei Chu et al. “Qwen2-audio technical report”. In: *arXiv preprint arXiv:2407.10759* (2024).
- [14] Jade Copet et al. *Simple and Controllable Music Generation*. 2024. arXiv: 2306.05284 [cs.SD]. URL: <https://arxiv.org/abs/2306.05284>.
- [15] Alexandre Défossez et al. “High fidelity neural audio compression”. In: *arXiv preprint arXiv:2210.13438* (2022).
- [16] Alexandre Défossez et al. “Moshi: a speech-text foundation model for real-time dialogue”. In: *arXiv preprint arXiv:2410.00037* (2024).
- [17] Soham Deshmukh et al. “Pengi: An audio language model for audio tasks”. In: *Advances in Neural Information Processing Systems* 36 (2023), pp. 18090–18108.
- [18] Ding Ding et al. “Kimi-audio technical report”. In: *arXiv preprint arXiv:2504.18425* (2025).
- [19] Zhihao Du et al. “Cosyvoice 2: Scalable streaming speech synthesis with large language models”. In: *arXiv preprint arXiv:2412.10117* (2024).
- [20] Zhihao Du et al. *CosyVoice: A Scalable Multilingual Zero-shot Text-to-speech Synthesizer based on Supervised Semantic Tokens*. 2024. arXiv: 2407.05407 [cs.SD]. URL: <https://arxiv.org/abs/2407.05407>.
- [21] Qingkai Fang et al. “Llama-omni: Seamless speech interaction with large language models”. In: *arXiv preprint arXiv:2409.06666* (2024).
- [22] Heting Gao et al. *LUCY: Linguistic Understanding and Control Yielding Early Stage of Her*. 2025. arXiv: 2501.16327 [cs.CL]. URL: <https://arxiv.org/abs/2501.16327>.
- [23] Jort F. Gemmeke et al. “Audio Set: An ontology and human-labeled dataset for audio events”. In: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017, pp. 776–780. DOI: 10.1109/ICASSP.2017.7952261.

- [24] Sreyan Ghosh et al. *Audio Flamingo 2: An Audio-Language Model with Long-Audio Understanding and Expert Reasoning Abilities*. 2025. arXiv: 2503.03983 [cs.SD]. URL: <https://arxiv.org/abs/2503.03983>.
- [25] Arushi Goel et al. *Audio Flamingo 3: Advancing Audio Intelligence with Fully Open Large Audio Language Models*. 2025. arXiv: 2507.08128 [cs.SD]. URL: <https://arxiv.org/abs/2507.08128>.
- [26] Yuan Gong, Jin Yu, and James Glass. “Vocalsound: A Dataset for Improving Human Vocal Sounds Recognition”. In: *ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2022, pp. 151–155. DOI: 10.1109/ICASSP43922.2022.9746828.
- [27] Yuan Gong et al. “Joint audio and speech understanding”. In: *2023 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU)*. IEEE. 2023, pp. 1–8.
- [28] Yuan Gong et al. “Listen, think, and understand”. In: *arXiv preprint arXiv:2305.10790* (2023).
- [29] Aaron Grattafiori et al. *The Llama 3 Herd of Models*. 2024. arXiv: 2407.21783 [cs.AI]. URL: <https://arxiv.org/abs/2407.21783>.
- [30] Wei-Ning Hsu et al. *HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units*. 2021. arXiv: 2106.07447 [cs.CL]. URL: <https://arxiv.org/abs/2106.07447>.
- [31] Ailin Huang et al. “Step-Audio-AQAA: a Fully End-to-End Expressive Large Audio Language Model”. In: *arXiv preprint arXiv:2506.08967* (2025).
- [32] Ailin Huang et al. “Step-audio: Unified understanding and generation in intelligent speech interaction”. In: *arXiv preprint arXiv:2502.11946* (2025).
- [33] Rongjie Huang et al. “Audiogpt: Understanding and generating speech, music, sound, and talking head”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38. 21. 2024, pp. 23802–23804.
- [34] Aaron Hurst et al. “Gpt-4o system card”. In: *arXiv preprint arXiv:2410.21276* (2024).
- [35] Il-Young Jeong and Jeongsoo Park. “CochlScene: Acquisition of acoustic scene data using crowdsourcing”. In: *2022 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*. 2022, pp. 17–21. DOI: 10.23919/APSIPAASC55919.2022.9979822.
- [36] Shengpeng Ji et al. “Wavtokenizer: an efficient acoustic discrete codec tokenizer for audio language modeling”. In: *arXiv preprint arXiv:2408.16532* (2024).
- [37] Ye Jia et al. *CVSS Corpus and Massively Multilingual Speech-to-Speech Translation*. 2022. arXiv: 2201.03713 [cs.CL]. URL: <https://arxiv.org/abs/2201.03713>.
- [38] Ye Jia et al. “Direct speech-to-speech translation with a sequence-to-sequence model”. In: *arXiv preprint arXiv:1904.06037* (2019).
- [39] Ye Jia et al. “Translatotron 2: High-quality direct speech-to-speech translation with voice preservation”. In: *International conference on machine learning*. PMLR. 2022, pp. 10120–10134.
- [40] Eugene Kharitonov et al. *Speak, Read and Prompt: High-Fidelity Text-to-Speech with Minimal Supervision*. 2023. arXiv: 2302.03540 [cs.SD]. URL: <https://arxiv.org/abs/2302.03540>.
- [41] Chris Dongjoo Kim et al. “Audiocaps: Generating captions for audios in the wild”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. 2019, pp. 119–132.
- [42] Jungil Kong, Jaehyeon Kim, and Jaekyoung Bae. *HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis*. 2020. arXiv: 2010.05646 [cs.SD]. URL: <https://arxiv.org/abs/2010.05646>.
- [43] Zhifeng Kong et al. *Audio Flamingo: A Novel Audio Language Model with Few-Shot Learning and Dialogue Abilities*. 2024. arXiv: 2402.01831 [cs.SD]. URL: <https://arxiv.org/abs/2402.01831>.
- [44] Chenyang Le et al. “Transvip: Speech to speech translation system with voice and isochrony preservation”. In: *Advances in Neural Information Processing Systems 37* (2024), pp. 89682–89705.
- [45] Ann Lee et al. “Textless speech-to-speech translation on real data”. In: *arXiv preprint arXiv:2112.08352* (2021).
- [46] Sang-gil Lee et al. *BigVGAN: A Universal Neural Vocoder with Large-Scale Training*. 2023. arXiv: 2206.04658 [cs.SD]. URL: <https://arxiv.org/abs/2206.04658>.
- [47] Guan-Ting Lin, Cheng-Han Chiang, and Hung-yi Lee. “Advancing large language models to capture varied speaking styles and respond properly in spoken conversations”. In: *arXiv preprint arXiv:2402.12786* (2024).
- [48] Guan-Ting Lin et al. “Paralinguistics-enhanced large language modeling of spoken dialogue”. In: *ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE. 2024, pp. 10316–10320.
- [49] Tu Anh Nguyen et al. *Spirit LM: Interleaved Spoken and Written Language Model*. 2024. arXiv: 2402.05755 [cs.CL]. URL: <https://arxiv.org/abs/2402.05755>.
- [50] OpenAI. *GPT-4 Technical Report*. <https://openai.com/research/gpt-4>. Accessed: 2025-07-11. 2023.

- [51] OpenAI. *Introducing ChatGPT*. Accessed: 2025-07-11. 2022. URL: <https://openai.com/blog/chatgpt>.
- [52] Wei Ping et al. “Deep voice 3: 2000-speaker neural text-to-speech”. In: *proc. ICLR*. Vol. 79. 2018, pp. 1094–1099.
- [53] Alec Radford et al. “Robust speech recognition via large-scale weak supervision”. In: *International conference on machine learning*. PMLR. 2023, pp. 28492–28518.
- [54] Rafael Rafailov et al. “Direct preference optimization: Your language model is secretly a reward model”. In: *Advances in Neural Information Processing Systems* 36 (2023), pp. 53728–53741.
- [55] Yi Ren et al. “Fastspeech 2: Fast and high-quality end-to-end text to speech”. In: *arXiv preprint arXiv:2006.04558* (2020).
- [56] Andrew Rouditchenko et al. “Omni-R1: Do You Really Need Audio to Fine-Tune Your Audio LLM?” In: *arXiv preprint arXiv:2505.09439* (2025).
- [57] Paul K Rubenstein et al. “Audiopalm: A large language model that can speak and listen”. In: *arXiv preprint arXiv:2306.12925* (2023).
- [58] S Sakshi et al. “Mmau: A massive multi-task audio understanding and reasoning benchmark”. In: *arXiv preprint arXiv:2410.19168* (2024).
- [59] Jonathan Shen et al. “Natural tts synthesis by conditioning wavenet on mel spectrogram predictions”. In: *2018 IEEE international conference on acoustics, speech and signal processing (ICASSP)*. IEEE. 2018, pp. 4779–4783.
- [60] Hubert Siuzdak, Florian Grötschla, and Luca A Lenzendörfer. “Snac: Multi-scale neural audio codec”. In: *arXiv preprint arXiv:2410.14411* (2024).
- [61] Changli Tang et al. “Salmonn: Towards generic hearing abilities for large language models”. In: *arXiv preprint arXiv:2310.13289* (2023).
- [62] Wolfgang Wahlster. *Verbmobil: foundations of speech-to-speech translation*. Springer Science & Business Media, 2013.
- [63] Changhan Wang, Anne Wu, and Juan Pino. *CoVoST 2 and Massively Multilingual Speech-to-Text Translation*. 2020. arXiv: 2007.10310 [cs.CL]. URL: <https://arxiv.org/abs/2007.10310>.
- [64] Chengyi Wang et al. “Neural codec language models are zero-shot text to speech synthesizers”. In: *arXiv preprint arXiv:2301.02111* (2023).
- [65] Xinsheng Wang et al. “Spark-tts: An efficient llm-based text-to-speech model with single-stream decoupled speech tokens”. In: *arXiv preprint arXiv:2503.01710* (2025).
- [66] Xiong Wang et al. “Freeze-omni: A smart and low latency speech-to-speech dialogue model with frozen llm”. In: *arXiv preprint arXiv:2411.00774* (2024).
- [67] Yuancheng Wang et al. “Maskgct: Zero-shot text-to-speech with masked generative codec transformer”. In: *arXiv preprint arXiv:2409.00750* (2024).
- [68] Yuxuan Wang et al. “Tacotron: Towards end-to-end speech synthesis”. In: *arXiv preprint arXiv:1703.10135* (2017).
- [69] Jason Wei et al. “Finetuned language models are zero-shot learners”. In: *arXiv preprint arXiv:2109.01652* (2021).
- [70] Yonghui Wu et al. “Google’s neural machine translation system: Bridging the gap between human and machine translation”. In: *arXiv preprint arXiv:1609.08144* (2016).
- [71] Zhifei Xie and Changqiao Wu. “Mini-omni: Language models can hear, talk while thinking in streaming”. In: *arXiv preprint arXiv:2408.16725* (2024).
- [72] Zhifei Xie and Changqiao Wu. “Mini-omni2: Towards open-source gpt-4o with vision, speech and duplex capabilities”. In: *arXiv preprint arXiv:2410.11190* (2024).
- [73] Detai Xin et al. “Bigcodec: Pushing the limits of low-bitrate neural speech codec”. In: *arXiv preprint arXiv:2409.05377* (2024).
- [74] Jin Xu et al. *Qwen2.5-Omni Technical Report*. 2025. arXiv: 2503.20215 [cs.CL]. URL: <https://arxiv.org/abs/2503.20215>.
- [75] Ruiqi Yan et al. *URO-Bench: A Comprehensive Benchmark for End-to-End Spoken Dialogue Models*. 2025. arXiv: 2502.17810 [cs.CL]. URL: <https://arxiv.org/abs/2502.17810>.
- [76] Neil Zeghidour et al. “Soundstream: An end-to-end neural audio codec”. In: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 30 (2021), pp. 495–507.
- [77] Aohan Zeng et al. “Glm-4-voice: Towards intelligent and human-like end-to-end spoken chatbot”. In: *arXiv preprint arXiv:2412.02612* (2024).
- [78] Binbin Zhang et al. *WenetSpeech: A 10000+ Hours Multi-domain Mandarin Corpus for Speech Recognition*. 2022. arXiv: 2110.03370 [cs.SD]. URL: <https://arxiv.org/abs/2110.03370>.
- [79] Bowen Zhang et al. “Minimax-speech: Intrinsic zero-shot text-to-speech with a learnable speaker encoder”. In: *arXiv preprint arXiv:2505.07916* (2025).

-
- [80] Dong Zhang et al. “Speechgpt: Empowering large language models with intrinsic cross-modal conversational abilities”. In: *arXiv preprint arXiv:2305.11000* (2023).
 - [81] Xiangyu Zhang et al. “Distinctive Feature Codec: Adaptive Segmentation for Efficient Speech Representation”. In: *arXiv preprint arXiv:2505.18516* (2025).
 - [82] Xin Zhang et al. “Spechtokenizer: Unified speech tokenizer for speech large language models”. In: *arXiv preprint arXiv:2308.16692* (2023).

Appendix

A Contributors

The contributors are list in alphabet order.

A.1 Core contributors

Model Boyong Wu, Chao Yan, Chen Hu, Cheng Yi, Chengli Feng, Fei Tian, Feiyu Shen, Gang Yu, Haoyang Zhang, Jingbei Li, Mingrui Chen, Peng Liu, Wang You, Xiangyu (Tony) Zhang, Xingyuan Li, Xuerui Yang, Yayue Deng, Yechang Huang, Yuxin Li, Yuxin Zhang, Zhao You

Infrastructure Brian Li, Changyi Wan, Hanpeng Hu, Jiangjie Zhen, Siyu Chen, Song Yuan, Xuelin Zhang, Yimin Jiang, Yu Zhou, Yuxiang Yang

Data and evaluation Bingxin Li, Buyun Ma, Changhe Song, Dongqing Pang, Guoqiang Hu, Haiyang Sun, Kang An, Na Wang, Shuli Gao, Wei Ji, Wen Li, Wen Sun, Xuan Wen, Yong Ren, Yuankai Ma, Yufan Lu

A.2 Contributors

Bin Wang, Bo Li, Changxin Miao, Che Liu, Chen Xu, Dapeng Shi, Dingyuan Hu, Donghang Wu, Enle Liu, Guanzhe Huang, Gulin Yan, Han Zhang, Hao Nie, Haonan Jia, Hongyu Zhou, Jianjian Sun, Jiaoren Wu, Jie Wu, Jie Yang, Jin Yang, Junzhe Lin, Kaixiang Li, Lei Yang, Liying Shi, Li Zhou, Longlong Gu, Ming Li, Mingliang Li, Mingxiao Li, Nan Wu, Qi Han, Qinyuan Tan, Shaoliang Pang, Shengjie Fan, Siqi Liu, Tiancheng Cao, Wanying Lu, Wenqing He, Wuxun Xie, Xu Zhao, Xueqi Li, Yanbo Yu, Yang Yang, Yi Liu, Yifan Lu, Yilei Wang, Yuanhao Ding, Yuanwei Liang, Yuanwei Lu, Yuchu Luo, Yuhe Yin, Yumeng Zhan, Yuxiang Zhang, Zidong Yang, Zixin Zhang

A.3 Sponsors

Binxing Jiao, Daxin Jiang, Heung-Yeung Shum, Jiansheng Chen, Jing Li, Xiangyu Zhang, Yibo Zhu

A.4 External contributors

Nanyang Technological University (NTU), Singapore Eng Siong Chng, Hexin Liu

B Introduction and evaluation results of Step-Audio 2 mini

We are pleased to release Step-Audio 2 mini, a special open-source version of Step-Audio 2, available at <https://github.com/stepfun-ai/Step-Audio2>. Step-Audio 2 mini employs the encoder from Qwen2-Audio as its audio encoder and is initialized with Qwen2.5-7B. Step-Audio 2 mini is trained on the same dataset as Step-Audio 2, but it is limited to utilize only the web search tool.

Step-Audio 2 mini is a more developer-friendly variant of Step-Audio 2, with a parameter count for fair comparisons with open-source models including Qwen-Omni and Kimi-Audio. Evaluation results¹ demonstrate that Step-Audio 2 mini delivers on par results with Step-Audio 2, exceeding most open-source and commercial models such as GPT-4o Audio.

B.1 Automatic speech recognition

Table 7: Comparison between Doubao LLM ASR, GPT-4o Transcribe, Kimi-Audio, Qwen-Omni, Step-Audio 2 and Step-Audio 2 mini, on character (for Chinese, Cantonese and Japanese) and word (for Arabian and English) error rates among multiple ASR test sets. N/A indicates that the language is not supported.

Category	Test set	Doubao LLM ASR	GPT-4o Transcribe	Kimi- Audio	Qwen- Omni	Step- Audio 2	Step-Audio 2 mini
English	Common Voice	9.20	9.30	7.83	8.33	5.95	6.76
	FLEURS English	7.22	2.71	4.47	5.05	3.03	3.05
	LibriSpeech clean	2.92	1.75	1.49	2.93	1.17	1.33
	LibriSpeech other	5.32	4.23	2.91	5.07	2.42	2.86
	Average	6.17	4.50	4.18	5.35	3.14	3.50
Chinese	AISHELL	0.98	3.52	0.64	1.17	0.63	0.78
	AISHELL-2	3.10	4.26	2.67	2.40	2.10	2.16
	FLEURS Chinese	2.92	2.62	2.91	7.01	2.68	2.53
	KeSpeech phase1	6.48	26.80	5.11	6.45	3.63	3.97
	WenetSpeech meeting	4.90	31.40	5.21	6.61	4.75	4.87
	WenetSpeech net	4.46	15.71	5.93	5.24	4.67	4.82
	Average	3.81	14.05	3.75	4.81	3.08	3.19
Multilingual	FLEURS Arabian	N/A	11.72	N/A	25.13	14.22	16.46
	Common Voice yue	9.20	11.10	38.90	7.89	7.90	8.32
	FLEURS Japanese	N/A	3.27	N/A	10.49	3.18	4.67
In-house	Anhui accent	8.83	50.55	22.17	18.73	10.61	11.65
	Guangdong accent	4.99	7.83	3.76	4.03	3.81	4.44
	Guangxi accent	3.37	7.09	4.29	3.35	4.11	3.51
	Shanxi accent	20.26	55.03	34.71	25.95	12.44	15.60
	Sichuan dialect	3.01	32.85	5.26	5.61	4.35	4.57
	Shanghai dialect	47.49	89.58	82.90	58.74	17.77	19.30
	Average	14.66	40.49	25.52	19.40	8.85	9.85

¹Evaluation results are obtained with our vLLM backend and may differ from the results with transformers backend.

B.2 Paralinguistic information understanding

Table 8: Comparison between GPT-4o Audio, Kimi-Audio, Qwen-Omni, Step-Audio-AQAA, Step-Audio 2 and Step-Audio 2 mini on StepEval-Audio-Paralinguistic.

Model	Avg.	Gender	Age	Timbre	Scenario	Event
GPT-4o Audio	43.45	18	42	34	22	14
Kimi-Audio	49.64	94	50	10	30	48
Qwen-Omni	44.18	40	50	16	28	42
Step-Audio-AQAA	36.91	70	66	18	14	14
Step-Audio 2	83.09	100	96	82	78	60
Step-Audio 2 mini	80.00	100	94	80	78	60

Model	Emotion	Pitch	Rhythm	Speed	Style	Vocal
GPT-4o Audio	82	40	60	58	64	44
Kimi-Audio	66	56	40	44	54	54
Qwen-Omni	76	32	54	50	50	48
Step-Audio-AQAA	40	38	48	54	44	0
Step-Audio 2	86	82	86	88	88	68
Step-Audio 2 mini	82	82	68	74	86	76

B.3 Audio understanding

Table 9: Comparison between Audio Flamingo 3, Gemini 2.5 Pro, GPT-4o Audio, Kimi-Audio, Omni-R1, Qwen2.5-Omni, Step-Audio-AQAA, Step-Audio 2 and Step-Audio 2 mini on MMAU.

Model	Avg.	Sound	Speech	Music
Audio Flamingo 3	73.1	76.9	66.1	73.9
Gemini 2.5 Pro	71.6	75.1	71.5	68.3
GPT-4o Audio	58.1	58.0	64.6	51.8
Kimi-Audio	69.6	79.0	65.5	64.4
Omni-R1	77.0	81.7	76.0	73.4
Qwen2.5-Omni	71.5	78.1	70.6	65.9
Step-Audio-AQAA	49.7	50.5	51.4	47.3
Step-Audio 2	78.0	83.5	76.9	73.7
Step-Audio 2 mini	73.2	76.6	71.5	71.6

B.4 Speech translation

Table 10: Comparison of BLEU scores between GPT-4o Audio, Qwen2.5-Omni, Qwen-Omni, Step-Audio-AQAA, Step-Audio 2 and Step-Audio 2 mini on speech-to-text and speech-to-speech translation.

Model	CoVoST 2 (Speech-to-text translation)		
	Avg.	English-to-Chinese	Chinese-to-English
GPT-4o Audio	29.61	40.20	19.01
Qwen2.5-Omni	35.40	41.40	29.40
Step-Audio-AQAA	28.57	37.71	19.43
Step-Audio 2	39.26	49.01	29.51
Step-Audio 2 mini	39.29	49.12	29.47

Model	CVSS (Speech-to-speech translation)		
	Avg.	English-to-Chinese	Chinese-to-English
GPT-4o Audio	23.68	20.07	27.29
Qwen-Omni	15.35	8.04	22.66
Step-Audio-AQAA	27.36	30.74	23.98
Step-Audio 2	30.87	34.83	26.92
Step-Audio 2 mini	29.08	32.81	25.35

B.5 Speech-to-speech conversation

Table 11: Comparison between GPT-4o Audio, Kimi-Audio, Qwen-Omni, Step-Audio-AQAA, Step-Audio 2 and Step-Audio 2 mini on the URO-Bench. U. R. O. stands for understanding, reasoning, and oral conversation, respectively.

Model	Language	Basic				Pro			
		Avg.	U.	R.	O.	Avg.	U.	R.	O.
GPT-4o Audio	Chinese	78.59	89.40	65.48	85.24	67.10	70.60	57.22	70.20
Kimi-Audio		73.59	79.34	64.66	79.75	66.07	60.44	59.29	76.21
Qwen-Omni		68.98	59.66	69.74	77.27	59.11	59.01	59.82	58.74
Step-Audio-AQAA		74.71	87.61	59.63	81.93	65.61	74.76	47.29	68.97
Step-Audio 2		83.32	91.05	75.45	86.08	68.25	74.78	63.18	65.10
Step-Audio 2 mini		77.81	89.19	64.53	84.12	69.57	76.84	58.90	69.42
GPT-4o Audio	English	84.54	90.18	75.90	90.41	67.51	60.65	64.36	78.46
Kimi-Audio		60.04	83.36	42.31	60.36	49.79	50.32	40.59	56.04
Qwen-Omni		70.58	66.29	69.62	76.16	50.99	44.51	63.88	49.41
Step-Audio-AQAA		71.11	90.15	56.12	72.06	52.01	44.25	54.54	59.81
Step-Audio 2		83.90	92.72	76.51	84.92	66.07	64.86	67.75	66.33
Step-Audio 2 mini		74.36	90.07	60.12	77.65	61.25	58.79	61.94	63.80